

第1讲 数据挖掘的基本认知

本章概念汇总 · 笔记整理

📖 数据挖掘与机器学习 · 课堂作业

涵盖大数据、数据挖掘、降维、监督/非监督学习、数据类型、预处理、标准化、衍生变量等核心概念

学生：张椅达 | 学号：202321054055

概念汇总目录

本章共涵盖 8 大核心概念 + 扩展内容

大数据

Big Data

4V特征: Volume、Variety
Value、Velocity

概念1

数据挖掘

Data Mining

从大量数据中提取隐含的
潜在有用信息和知识

概念2

数据降维

Dimension Reduction

PCA (线性降维)
t-SNE (非线性降维)

概念3

监督 vs 非监督

Supervised / Unsupervised

有标签 vs 无标签
分类/回归 vs 聚类/关联

概念4

数据结构类型

Three Data Forms

结构化 / 半结构化
/ 非结构化数据

概念5

数据预处理与清洗

Preprocessing & Cleaning

缺失值/噪声/不一致/重复
清洗→集成→归约→变换

概念6

标准化与归一化

Normalization / Standardization

Z-score标准化
Min-Max归一化

概念7

衍生变量

Derived Variable

多项式/比率/分箱
时间/聚合特征

概念8

客服：陈先生，海鲜披萨不适合您。

顾客：为什么？

客服：根据您的医疗记录，您的血压和胆固醇都偏高。

顾客：那你们有什么可以推荐的？

客服：您可以试试我们的低脂健康披萨。

顾客：你怎么知道我会喜欢吃这种的？

客服：您上星期一在国家图书馆借了一本《低脂健康食谱》。

顾客：好。那我要一个家庭特大号披萨，要付多少钱？

客服：99元，这个足够您一家六口吃了。但您母亲应该少吃，她上个月刚刚做了心脏搭桥手术，还处在恢复期。

顾客：那可以刷卡吗？

客服：陈先生，对不起。请您付现款，因为您的信用卡已经刷爆了，您现在还欠银行4807元，而且还不包括房贷利息。

顾客：那我先去附近的提款机取款。

客服：陈先生，根据您的记录，您已经超过今日取款限额。

顾客：算了，你们直接把披萨送我家吧，家里有现金。你们多久会送到？

客服：大约30分钟。如果您不想等，可以自己骑车来。

顾客：为什么？

客服：根据我们CRM全球定位系统的车辆行驶自动跟踪系统记录。您登记有一辆车号为SB-748的摩托车，而目前您正在解放路东段华联商场右侧骑着这辆摩托车。

顾客：当即晕倒……

何为大数据 数据量大 数据源复杂 应用场景众多

在这则故事里，必胜客为何对这位客户的饮食、健康、行踪等信息一切了然呢？必胜客借助的就是存在于各种载体内的关于这位客户的数据，而这些数据就可以称之为大数据。现在我们再来看看学术上关于大数据的定义。

大数据 又称海量数据，指的是以不同形式存在于数据库、网络等媒介上蕴含丰富信息的规模巨大的数据。大数据是一个宽泛的概念，其定义也是见仁见智。诚然“大”是大数据的一个重要特征，但远远不是全部，不能单纯根据数据规模来定义大数据，因为不同时期，由于数据存储能力的不同，人们衡量数据规模的尺度也是不一样的。

大数据同过去的海量数据有所区别，其基本特征可以用4个V来总结（Volume、Variety、Value和Velocity），具体含义为：

① **Volume**，数据体量巨大，可以是TB级别，也可以是PB级别。

② **Variety**，数据类型繁多，如网络日志、视频、图片、地理位置信息等。物联网、云计算、移动互联网、车联网、手机、平板电脑、PC以及遍布地球各个角落的各种各样的传感器，无一不是数据来源或者承载的方式。

③ **Value**，价值密度低。以视频为例，连续不间断监控过程中，可能有用的数据仅仅有一两秒。

④ **Velocity**，处理速度快，这一点与传统的数据挖掘技术有着本质的不同。简而言之，大数据的特点是体量大、多样性、价值密度低、速度快。

1.1.2 大数据的价值

从1.1.1节必胜客的故事我们可以感知到大数据的价值。大数据的价值，有的时候很容易通过简单的信息检索，或简单的统计分析得到，就像必胜客所做的那样。但很多情况下，很难直接获取数据的价值，需要通过更复杂的方法去获取数据中隐含的模式和规则，以利用这些规则或模式去指导和预测未来。换句话说，就是要向数据学习社会生活中的规则。就像电影《超能查派》中的那个机器人一样（如图1-1所示），通过向数据进行学习，几天之内就学会了超人的技能，而这些技能就是大数据中蕴藏的。

无论是必胜客的故事还是电影《超能查派》，都为我们揭示了大数据的价值。而这种价值不同于物质性的东西，大数据的价值不会随着它的使用而减少，而是可以不断地被处理。大数据的价值并不仅仅限于特定的用途，它可以为了同一目的而被多次使用，亦可用于其他目的。最终，大数据的价值是其所有可能用途的总和。知名IT评论人谢文表示，“大数据将逐渐成为现代社会基础设施的一部分，就像公路、铁路、港口、水电和通信网络一样不可或缺。但就其价值特性而言，大数据却和这些物理化的基础设施不同，不会因为使用而折旧和贬值。例如，一组DNA可能会死亡或毁灭，但大数据的DNA却会永存”。

大数据研发的目的是利用大数据技术去发现大数据的价值并将其应用到相关领域，通过解决大数据的处理问题促进社会的发展。从大数据中发现价值的一系列技术可以称之为数据挖掘。

1.1.3 大数据与数据挖掘的关系

时下，大数据这个概念很火，数据挖掘这个技术也很热，大数据与数据挖掘到底有怎样的关系呢？一般的认识是这样的，大数据只是个概念，围绕这个概念，有两大技术分支，如



图1-1 电影《超能查派》中的机器人

（图片来源：<http://mt.sohu.com/20150502/n412271291.shtml>）

1.3.2 回归

回归 (Regression) 是确定两种或两种以上变量间相互定量关系的一种统计分析方法。回归是数据挖掘中最为基础的方法,也是应用领域和应用场景最多的方法,只要是量化型问题,我们一般都会先尝试用回归方法来研究或分析。比如要研究某地区钢材消费量与国民收入的关系,那么就可以直接用这两个变量的数据进行回归,然后看看它们之间的关系是否符合某种形式的回归关系,如图 1-7 所示。

根据回归方法中因变量的个数和回归函数的类型 (线性或非线性) 可将回归方法分为以下几种:一元线性、一元非线性、多元线性、多元非线性。另外还有两种特殊的回归方式,一种是在回归过程中可以调整变量数的回归方法,称为逐步回归,另一种是以指数结构函数作为回归模型的回归方法,称为 Logistic 回归,这些方法的关系如图 1-8 所示。




图 1-7 回归方法得到的钢材消费量与国民收入的关系图




图 1-8 回归方法结构图

1.3.3 分类

分类是一个常见的问题,在我们的日常生活中就会经常遇到分类的问题,比如垃圾分类 (如图 1-9 所示)。在数据挖掘中,分类也是最为常见的问题,其典型的应用就是根据事物在数据层面表现的特征,对事物进行科学的分类。

对于分类问题,人们已经研究并总结出了很多有效的方法。到目前为止,已经研究出的经典分类方法主要包括:决策树方法 (经典的决策树算法主要包括 ID3 算法、C4.5 算法和 CART 算法等)、神经网络方法、贝叶斯分类、K-近邻算法、判别



图 1-9 分类示意图

(图片来源: <http://www.ifashbuy.com/i/news/a/2013/1105/876.html>)

分析、支持向量机等分类方法,如图 1-10 所示。不同的分类方法有不同的特点。这些分类方法在很多领域都得到了成功的应用,比如决策树方法已经成功地应用到医学诊断、贷款风险评估等领域;神经网络则因为对噪声数据有很好的承受能力而在实际问题中得到了非常成功的应用,比如识别手写字符、语音识别和人脸识别等。但是由于每一种方法都有缺再加上实际问题的复杂性和数据的多样性,使得无论哪一种方法都只能解决某一类问题。近年来,随着人工智能、机器学习、模式识别和数据挖掘等领域中传统方法的不断发及各种新方法和新技术的不断涌现,分类方法得到了长足的发展。

1.3.4 聚类

聚类分析 (Cluster Analysis) 又称群分析,是根据“物以类聚”的道理,对样品进行分类的一种多元统计分析方法,它们讨论的对象是大量的样品,要求能合理地按各自的进行合理的分类,没有任何模式可供参考或依据,是在没有先验知识的情况下进行的是将数据分类到不同的类或者簇的一个过程,所以同一个簇中的对象有很大的相似性,同簇间的对象有很大的相异性。聚类分析起源于分类学,在古老的分类学中,人们三经验和专业知识来实现分类,很少利用数学工具进行定量的分类。随着人类科学技术对分类的要求越来越高,以致有时仅凭经验和专业知识难以确切地进行分类,于是地把数学工具引用到了分类学中,形成了数值分类学,之后又将多元分析的技术引分类学形成了聚类分析。更直接地说,聚类是看样品大致分成几类,然后再对样品也就是说,聚类是为了更合理地分类。比如,在图 1-11 中,通过聚类发现这些点类,那么对于新的数据,就可以按照 3 类的标准进行归类。




图 1-10 经典分类方法

(图片来源: <http://www.itongji.cn/article/0R52D42013.html>)

在不同的应用领域,很多聚类技术都得到了发展,这些技术方法被用作不同数据源间的相似性,以及把数据源分类到不同的簇中。在商业上,聚类不同的客户群,并且通过购买模式刻画不同客户群的特征;在生物上,聚类




图 1-11 聚类示意图

可以简称为 DPEMED (Definition、Preparation、Explore、Modeling、Evaluation、Deployment)
模型, 它们之间的关系如图 2-1 所示。

2.2 挖掘目标的定义

企业或组织机构当想要实施数据挖掘时, 十有八九是因为觉得积累的业务数据里有些有价值的东西, 也就是说在潜意识里面已经有了大致的目标了。这种目标在无形之中会给随后的数据挖掘过程给出明确的目标, 所谓有的放矢, 这样数据挖掘就可以有意义地进行下去。因此, 实施数据挖掘的第一步要确定数据挖掘的目标。

但要确定目标, 就必须要了解数据和相关的业务。比如, 要分析电信领域的客户呼叫行为, 需要了解电信的业务构成、业务运营以及其他诸多的行业知识。有关业务问题, 指的是在业务过程中您需要解决的问题、想要知道的答案并且认为这些问题的答案蕴藏在大量的数据中, 但并不知道它们在哪里。可能涉及的业务问题很多, 从数据挖掘的角度, 所需要了解的业务问题至少包含以下三个方面:

- 1) 有关需要解决问题的明确定义;
- 2) 对有关数据的了解;




图 2-1 数据挖掘过程示意图

据质量分析结果删除一些属性。在数据探索阶段，随着对数据的数据抽样，这时用的方法也会复杂些，比如相关性分析和主成分分析——这两种方法将在第5章详细介绍。

4.3.6 数据变换

将数据从一种表示形式变为另一种表现形式的过程。常用的数据变换方式是数据标准化、离散化和语义转换。

1. 标准化

数据的标准化 (Normalization) 是将数据按比例缩放，使之落入一个小的特定区间。在某些比较和评价的指标处理中经常会用到，去除数据的单位限制，将其转化为无量纲的纯数值，便于不同单位或量级的指标能够进行比较和加权。其中最典型的的就是 0-1 标准化和 Z-score 标准化：

(1) 0-1 标准化 (0-1 Normalization)

也叫离差标准化，是对原始数据的线性变换，使结果落到[0,1]区间，转换函数如下：

$$x^* = \frac{x - \min}{\max - \min}$$

其中，max 为样本数据的最大值；min 为样本数据的最小值。这种方法有一个缺陷就是当有新数据加入时，可能导致 max 和 min 的变化，需要重新定义。

(2) Z-score 标准化 (Zero-mean normalization)

也叫标准差标准化，经过处理的数据符合标准正态分布，即均值为 0，标准差为 1，最为常用的标准化方法，其转化函数为：

$$x^* = \frac{x - \mu}{\sigma}$$

其中， μ 为所有样本数据的均值； σ 为所有样本数据的标准差。

2. 离散化

5.1 衍生变量

5.1.1 衍生变量的定义指标

衍生变量，顾名思义是由其他既有变量通过不同形式的组合而衍生出的变量。例如，经知道一个长形物体的质量、长度、体积，现在就可以通过对现有三个变量的组合得到有用的衍生变量，如密度=质量/体积，线密度=质量/长度。

在数据挖掘过程中，通常需要对现有的变量进行各种形式的衍生，以得到更多可用的

衍生变量与原始变量有一定的相关性，但能更直观地反映事物的某些特征，表现

| 一、大数据 (Big Data)

大数据，又称海量数据，指的是以不同形式存在于数据库、网络等媒介上蕴含丰富信息的规模巨大的数据。

4V 基本特征

Volume



数据体量巨大

TB/PB级别数据存储

挑战：存储怎么做？

Variety



数据类型繁多

结构化/半结构化/非结构化

挑战：多源如何融合？

Value



价值密度低

海量数据中高价值信息占比低

挑战：如何挖掘价值？

Velocity



处理速度快

实时/近实时处理需求

挑战：计算速度要求

何为大数据？数据量大、数据结构复杂、应用场景众多！

| 二、数据挖掘 (Data Mining)

数据挖掘是从

经典概念：每一个点都重要

DIKW 层级体系



相关概念关系

人工智能 ⊃ 机器学习 (ML) ⊃ 神经网络 (NN) ⊃ 深度学习 (DNN)

数据挖掘与机器学习交叉融合，共享大量核心算法

数据挖掘是大数据价值链上的关键一环 — 从数据到知识、从信息到智慧的核心转换器

三、数据降维 (Dimension Reduction)

通过线性或非线性变换将原始高维特征空间映射到低维空间，消除冗余和噪声、降低计算复杂度、缓解 **"维度灾难"**

两种经典方法对比

Principal Component Analysis  PCA

主成分分析

线性降维方法

通过正交变换将可能相关的变量
转换为线性不相关的主成分
按方差大小排序，保留前k个主成分

适用于数据压缩、去噪、可视化

t-Distributed Stochastic Neighbor Embedding  t-SNE

t分布随机邻域嵌入

非线性降维方法

适用于高维数据的可视化
保留数据的局部结构
将相似的数据点在低维空间中聚集

适用于探索性数据分析、可视化

四、有监督 vs 无监督学习

Supervised Learning vs Unsupervised Learning

对比维度	有监督学习	无监督学习
训练数据	有标签（Label），已知类别或数值	无标签，只有输入特征
学习目标	学习输入到输出的映射，预测新数据	发现数据内在的结构、分布或模式
典型任务	分类、回归	聚类、关联规则、降维
代表算法	决策树、KNN、SVM Logistic回归、神经网络	K-means、层次聚类、DBSCAN Apriori、PCA
先验知识	需要已有标注的"正确答案"	无需先验知识，自动探索

核心区别：有监督需要标签，解决"已知问题"；无监督无需标签，发现"未知模式"

五、数据类型的三种形态

Structured / Semi-Structured / Unstructured Data

结构化数据

定义

具有明确的行列结构，可用二维表逻辑表达

示例

关系数据库中的客户表、订单表
Excel 表格、CSV 文件

特点

预定义的数据模型
严格的数据类型和约束
易于查询和分析

传统数据仓库处理

半结构化数据

定义

具有一定的结构但不严格遵循数据模型，Schema自描述

示例

XML 文档
JSON 数据
HTML 网页

特点

隐含结构而非显式定义
自描述标记语言

Web API / 日志数据

非结构化数据

定义

没有预定义的数据模型
结构不规则或不完整

示例

文本、邮件
图像、音频、视频
社交媒体帖子

特点

存储格式多样
分析处理难度大
需要NLP/CV等技术

大数据主要来源

六、数据预处理与数据清洗

Data Preprocessing & Cleaning

数据清洗：处理四大类问题

🔍 缺失值

删除含有缺失值的样本
填充（均值/中位数/众数）
插值法处理

🔄 噪声数据

平滑处理（分箱）
聚类识别异常值
回归拟合修正

🔄 不一致数据

纠正编码不一致
统一单位不统一
格式标准化

🔲 重复数据

完全重复记录去重
部分重复合并

预处理四步骤

Step 1

数据清洗

处理缺失、噪声、不一致

Step 2

数据集成

合并多源异构数据

Step 3

数据归约

降维、特征选择

Step 4

数据变换

标准化、离散化、规范化

数据预处理是数据挖掘中最耗时但最关键的一步 — "垃圾进，垃圾出"

七、数据标准化与归一化

Standardization vs Normalization

统称**"无量纲化"**，目的是消除不同特征量纲和量级差异对模型的影响

Standardization (Z-score)

二标准化

$$z = \frac{(x - \mu)}{\sigma}$$

将数据转换为均值为0、标准差为1的分布

适用场景

数据近似正态分布
算法要求零均值（如SVM、PCA）
存在离群点的数据

输出范围不固定，适合有异常值场景

Normalization (Min-Max)

三归一化

$$x' = \frac{(x - x_{\min})}{(x_{\max} - x_{\min})}$$

将数据线性映射到 [0, 1] 范围

适用场景

不要求分布形态
特征尺度差异大（如神经网络、KNN）
数据有明确上下界

输出固定在[0,1]，受离群点影响较大

注意：决策树/随机森林基于阈值分裂，与特征量纲无关，无需标准化或归一化！KNN/SVM/LR 等基于距离或梯度的模型则必须进行特征缩放。

八、衍生变量 (Derived Variable)

特征工程的核心环节

从原始变量中通过**数学变换、组合或业务逻辑**构造出的新变量，
用于更好地捕捉数据中的模式和关系

五种常见构造方式

f 多项式

x^2, x^3
 $x_1 \cdot x_2$

捕捉非线性关系
交互效应

回归分析常用

比率/差值

x_1 / x_2
 $x_1 - x_2$

反映相对关系
增长率/变化量

财务指标常用

分箱

连续 $\rightarrow$ 离散
年龄 $\rightarrow$ 年龄段

离散化处理
降低噪声影响

信用评分常用

时间特征

年、月、日
星期、是否节假日

时间序列分析
周期性模式

销量预测常用

聚合特征

均值、总和、计数
最大、最小、标准差

多对一关系汇总
用户行为统计

客户画像常用

特征工程决定了模型性能的上限 — 好的衍生变量能大幅提升模型表现

补充：数据挖掘六阶段生命周期模型

CRISP-DM 标准流程框架



各阶段关键任务

- 1. 目标定义：明确问题与量化指标
- 4. 模型建立：选择算法 → 训练模型

- 2. 数据准备：选择 → 质量分析 → 预处理
- 5. 模型评估：准确率 → ROC → 回测验证

- 3. 数据探索：描述统计 → 可视化 → 探索建模
- 6. 模型部署：嵌入业务系统或分析参考

重点回顾

第1讲 数据挖掘的基本认知 · 核心概念一句话总结

大数据

4V特征 (Volume、Variety、Value、Velocity) 定义了大数据的核心属性

数据降维

PCA (线性) 和 t-SNE (非线性) 是两种经典降维方法

数据结构类型

结构化 (表)、半结构化 (XML/JSON)、非结构化 (文本/图像)

标准化与归一化

标准化(Z-score)和归一化(Min-Max)消除量纲影响; 决策树无需缩放

六阶段生命周期

目标定义 → 数据准备 → 数据探索 → 模型建立 → 模型评估 → 模型部署 (可回溯迭代)

数据挖掘

从大量有噪声的数据中提取隐含的、潜在有用的信息和知识

有监督 vs 无监督

有监督需要标签用于分类/回归; 无监督无标签用于聚类/关联

预处理与清洗

清洗→集成→归约→变换; "垃圾进, 垃圾出"

衍生变量

特征工程决定模型性能上限, 好的衍生变量能大幅提升模型表现

牢记这些基础概念, 为后续回归、分类、聚类、关联规则的学习打下坚实基础