

数据挖掘与机器学习-课后作业

数据回归分析方法

学生：张椅达 | 学号：202321054055 | 日期：3.18

目录



1. 回归分析的基本方法与步骤



2. 一元线性回归数学模型



3. 多元线性回归数学模型



4. Logistic回归数学模型及特点



5. Logistic回归与线性回归的联系与区别



6. 《白话机器学习》读书笔记

回归分析的基本方法与步骤



收集包含因变量(Y)和自变量(X)的数据集，确保数据质量。



选定因变量和自变量之间的模型，即一个数学式子，利用数据按照一定准则（如：最小二乘法、极大似然估计、损失函数法等）计算模型中的系数；



利用统计分析方法对不同模型进行比较，找出效果最优的模型。



判断得到的模型是否适合于这组数据。



利用模型对因变量作出预测或进行解释。

人民邮电出

京：机械工业

：清华大学

，2012.

现象 → 本质 回归到事物的本质

当人们对研究对象的内在特性和各因素间的关系有比较充分的认识时，一般用机理分析方法建立数学模型。如果由于客观事物内部规律的复杂性及人们认识程度的限制，无法分析实际对象内在的因果关系，建立合乎机理规律的数学模型，那么通常的办法是搜集大量数据，基于对数据的统计分析去建立模型。数据挖掘正是处理数据的技术，本章将讨论数据挖掘中用途非常广泛的一类方法——回归方法。

①事物之间的关系可以抽象为变量之间的关系。②变量之间的关系可以分为两类：一类叫确定性关系，也叫函数关系，其特征是：一个变量随着其他变量的确定而确定。另一类关系叫相关关系，变量之间的关系很难用一种精确的方法表示出来。例如，通常人的年龄越大血压越高，但人的年龄和血压之间没有确定的数量关系，人的年龄和血压之间的关系就是相关关系。③回归方法就是处理变量之间的相关关系的一种数学方法。其解决问题的大致方法、步骤如下：

- ④回归分析的意义在于更加有效的描述、解释和预测事物(变量)之间的关系。
- 1) 收集一组包含因变量和自变量的数据；
 - 2) 选定因变量和自变量之间的模型，即一个数学式子，利用数据按照一定准则(如最小二乘)计算模型中的系数；
 - 3) 利用统计分析方法对不同的模型进行比较，找出效果最好的模型；
 - 4) 判断得到的模型是否适合于这组数据；
 - 5) 利用模型对因变量作出预测或解释。

回归在数据挖掘中是最为基础的方法，也是应用领域和应用场景最多的方法，只要是量化型问题，我们一般都会先尝试用回归方法来研究或分析。

根据回归方法中因变量的个数和回归函数的类型(线性或非线性)可将回归方法分为以

2. 一元线性回归数学模型

定义

研究一个自变量 X 与一个因变量 Y 之间线性关系的回归分析方法。

基本形式

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Y 因变量（响应变量）

X 自变量（解释变量）

β_0 截距项

β_1 斜率系数（回归系数）

ε 随机误差项，代表模型未能解释的部分



通过确定参数 β_0 和 β_1 ，建立 X 与 Y 之间的线性预测关系。

7.1 一元回归

7.1.1 一元线性回归

设 Y 是一个可观测的随机变量, 它受到一个非随机变量因素 x 和随机误差 ε 影响。若 Y 与 x 有如下线性关系:

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

且 ε 的均值 $E(\varepsilon) = 0$, 方差 $\text{var}(\varepsilon) = \sigma^2 (\sigma > 0)$, 其中 β_0, β_1 是固定的未知参数, 称为回归系数, Y 称为因变量, x 称为自变量, 则称此 Y 与 x 之间的函数关系表达式为一元线性回归模型。


对于实际问题, 要建立回归方程, 首先要确定能否建立线性回归模型, 其次确定如何对模型中的未知参数 β_0, β_1 进行评估 (估计)。

通常, 我们首先对总体 (x, Y) 进行 n 次独立观测, 获得 n 组数据 (称为样本观测值):

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

然后在直角坐标系 xOy 中画出数据点 $(x_i, y_i), (i=1, 2, \dots, n)$, 该图形称为数据的散点图。如果这些点大致地位于同一条直线的附近, 或者说, 散点图呈现线性形状, 则认为 Y 与 x 之间的关系符合线性关系。此时, 利用最小乘法可以得到回归模型参数 β_0, β_1 的最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1$, 估计公式为:

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 \\ \hat{\beta}_1 = \frac{L_{xy}}{L_{xx}} \end{cases}$$



$$\text{其中, } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, L_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

于是就可以建立经验模型:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\begin{aligned} SSE &= \sum (y_i - \hat{y}_i)^2 \\ SST &= \sum (y_i - \bar{y})^2 \end{aligned}$$

对于得到的回归方程形式, 通常需要进行回归效果的评价, 当有几种回归结果后, 还需要加以比较以选出较好的方程, 常用的准则有:

1) 决定系数 R^2 , 其数学定义为:

$$R^2 = 1 - \frac{SSE}{SST}$$

估值强

R^2 称为决定系数。显然 $R^2 \leq 1$, R^2 大表示观测值 y_i 与拟合值 $\hat{y}_i$ 比较靠近, 也就意味着

3. 多元线性回归数学模型



定义：研究多个自变量 $X_1, X_2, \dots, X_p$ 与一个因变量 Y 之间线性关系的回归分析方法。



基本形式： $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$

Y

因变量

$X_1 \dots X_p$

p 个自变量

β_0

截距项

$\beta_1 \dots \beta_p$

偏回归系数

ε

随机误差项

7.2 多元回归

7.2.1 多元线性回归

线性的 加减仍是线性

设 Y 是一个可观测的随机变量, 它受到 $p(p > 0)$ 个非随机变量因素 $X_1, X_2, \dots, X_p$ 和随机误差 ε 的影响。若 Y 与 $X_1, X_2, \dots, X_p$, 有如下线性关系:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

正态分布

其中, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ 是固定的未知参数, 称为回归系数; ε 是均值为 0、方差为 $\sigma^2 (\sigma > 0)$ 的随机变量; Y 称为被解释变量; $X_1, X_2, \dots, X_p$ 称为解释变量。此模型称为多元线性回归模型。

自变量 $X_1, X_2, \dots, X_p$ 是非随机的且可精确观测, 随机误差 ε 代表其随机因素对因变量 Y 产生的影响。

对于总体 $(X_1, X_2, \dots, X_p; Y)$ 的 n 组观测值 $(x_{i1}, x_{i2}, \dots, x_{ip}; y_i) (i = 1, 2, \dots, n; n > p)$, 应满足式:

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \dots + \beta_p x_{1p} + \varepsilon_1 \\ y_2 = \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \dots + \beta_p x_{2p} + \varepsilon_2 \\ \dots \\ y_n = \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \dots + \beta_p x_{np} + \varepsilon_n \end{cases}$$

最小二乘法

其中 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$, 相互独立, 且设 $\varepsilon_i \sim N(0, \sigma^2) (i = 1, 2, \dots, n)$, 记

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

一元线性回归
方法, 同样适用
于多元

则模型可用矩阵形式表示为:

$$Y = X\beta + \varepsilon$$

其中, Y 称为观测向量; X 称为设计矩阵; β 称为待估计向量; ε 是不可观测的随机误差向量。

4. Logistic回归数学模型及特点



特殊性：定性变量与二分类

因变量 y 可能有两种情形：1.当 y 是一个定量的变量（连续的），这时就用通常的regress函数对 y 进行回归；
2.当 y 是一个定性的变量，比如 $y=0$ 或 1 （离散的），这时就不能用一般的regress函数对 y 进行回归，而是用Logistic回归。例如，预测股票的涨和跌（**二分类问题**）、是否给客户贷款等。



核心思想：预测概率而非类别

不直接预测类别 Y ，而是预测事件发生的概率 $P(Y=1|X)$ 。

31,22,44;2,54,18,22;21,47,4,26;1,40,23,34;11,66,9,12]; %自变量数据
Y=[78.5,74.3,104.3,87.6,95.9,109.2,102.7,72.5,93.1,115.9,83.8,113.3]; %因变量数据
Stepwise (X,Y,[1,2,3,4],0.05,0.10) % in=[1,2,3,4]表示X1、X2、X3、X4均保留在模型中
程序执行后得到下列逐步回归的窗口,如图7-6所示。




图7-6 逐步回归操作界面

图7-6显示变量X1、X2、X3、X4均保留在模型中,窗口的右侧按钮上方提示:将变量X3剔除回归方程(Move X3 out),单击“Next Step”按钮,即进行下一步运算,将第3列数据对应的变量X3剔除回归方程。单击“Next Step”按钮后,剔除的变量X3所对应的行用红色表示,同时又得到提示:将变量X4剔除回归方程(Move X4 out),单击“Next Step”按钮,这样一直重复操作,直到“Next Step”按钮变灰,表明逐步回归结束,此时得到的模型即为逐步回归最终的结果。

7.4 Logistic 回归

7.4.1 Logistic 模型

在回归分析中,因变量 y 可能有两种情形:① y 是一个定量的变量,这时就用通常的regress函数对 y 进行回归;② y 是一个定性的变量,比如 $y=0$ 或 1 ,这时就不能用通常的regress函数对 y 进行回归,而是使用所谓的Logistic回归。Logistic方法主要应用在研究某些现象发生的概率 p ,比如股票涨还是跌,公司成功或失败的概率。除此之外,本章还讨论概率 p 与哪些因素有关。Logistic回归模型的基本形式为:

$$p(Y=1|x_1, x_2, \dots, x_k) = \frac{\exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}{1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}$$

其中, $\beta_0, \beta_1, \dots, \beta_k$ 为类似于多元线性回归模型中的回归系数。

第7章 数据回归方法 145

该式表示当变量为 $x_1, x_2, \dots, x_k$ 时,自变量 p 为1的概率。对该式进行对数变换,可得:

$$\ln \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

至此,我们会发现,只要对因变量 p 按照 $\ln(p/(1-p))$ 的形式进行对数变换,就可以将Logistic回归问题转化为线性回归问题,此时就可以按照多元线性回归的方法很容易地得到回归参数。但很快又会发现,对于定性实践, p 的取值只有0,1,这就导致 $\ln(p/(1-p))$ 形式失去意义。为此,在实际应用Logistic模型的过程中,常常不是直接对 p 进行回归,而是先定义一种单调连续的概率函数 π ,令

$$\pi = p(Y=1|x_1, x_2, \dots, x_k), \quad 0 < \pi < 1$$

有了这样的定义,Logistic模型就可变形为:

$$\ln \frac{\pi}{1-\pi} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k, \quad 0 < \pi < 1$$

虽然形式相同,但此时的 π 为连续函数。然后只需要对原始数据进行合理的映射处理,就可以用线性回归方法得到回归系数。最后再由 π 和 p 的映射关系进行反映射而得到 p 的值。下面以一个实例来更具体地介绍如何用MATLAB进行Logistic回归分析。

7.4.2 Logistic 回归实例

企业到金融商业机构贷款,金融商业机构需要对企业进行评估。评估结果为0,1两种形式,0表示企业两年后破产,将拒绝贷款,而1表示企业两年后具备还款能力,可以贷款。在表7-8中,已知前20家企业的三项评价指标值和评估结果,试建立模型对其他5家企业(企业21~25)进行评估。

表7-8 企业还款能力评价表

企业编号	X1	X2	X3	Y	预测值
1	-62.8	-89.5	1.7	0	0
2	3.3	-3.5	1.1	0	0
3	-120.8	-103.2	2.5	0	0
4	-18.1	-28.8	1.1	0	0
5	-3.8	-50.6	0.9	0	0
6	-61.2	-56.2	1.7	0	0
7	-20.3	-17.4	1	0	0
8	-194.5	-25.8	0.5	0	0
9	20.8	-4.3	1	0	0
10	-106.1	-22.9	1.5	1	1
11	43	16.4	1.3	1	1
12	47	16	1.9	1	1
13	-3.3	4	2.7	1	1

5. Logistic回归与线性回归的联系与区别

- 该式表示当变量为 $x_1, x_2, \dots, x_k$ 时, 自变量 为1的概率。对该式进行对数变换, 可得:

$$\ln \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

令 $\pi = P(Y = 1 \mid x_1, x_2, \dots, x_k)$, $0 < \pi < 1$, Logistic模型就可变形为:

$$\ln \frac{\pi}{1-\pi} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

然后只需要对原始数据进行合理的映射处理, 就可以用**线性回归方法**得到回归系数。最后再由 π 和 p 的映射关系进行反映射而得到 p 的值。



5. Logistic回归与线性回归的联系与区别

二、两者的区别

因变量类型

一元、多元线性回归：因变量 (Y) 是连续型数值变量。例如：房价（元）、温度（℃）、销售额（万元）。它的取值在实数范围内，有具体的数学意义。

Logistic回归：因变量 (Y) 是离散型分类变量。通常用于二分类（0 或 1）。例如：是否生病（是/否）、邮件是否为垃圾邮件（是/否）、用户是否会点击广告（点击/不点击）。它输出的是一个概率值 ($P(Y=1)$)，而不是具体的数值。

6. 《白话机器学习》第六章 读书笔记

定义与核心

- 定义：预测连续值（如房价）
- 核心：寻找最佳拟合线，使数据点尽可能靠近

关键概念

- 预测变量与回归系数
- 相关系数与标准化
- 梯度下降法求解

经典示例

- 波士顿房价预测：
- 利用房屋特征（如房间数、位置）建立回归模型，预测房价走势。

局限性

- 敏感性：对异常值非常敏感，易受干扰。
- 多重共线性：变量间高度相关会影响模型稳定性。
- 线性假设：无法处理非线性趋势的数据。

小结与适用场景

- 适用条件：数据需满足线性关系、变量独立且无显著异常值。
- 地位：回归分析是预测分析的基石，简单高效。