

第三讲 分类算法

课后作业 · 笔记整理

KNN · 决策树 · 神经网络 · 朴素贝叶斯

学生：张椅达 | 学号：202321054055

类,尽管这些未来的测试数据的类标签是未知的,我们仍可以由此预测这些新数据所属的类。注意是预测,而不能肯定,因为分类的准确率不能达到百分之百。我们也可以由此对数据中的每一个类有更好的理解。也就是说:我们获得了对这个类的知识。

所以分类(Classification)也可以定义为:

对现有的数据进行学习,得到一个目标函数或规则,把每个属性集 x 映射到一个预先定义的目标函数 y 。

目标函数或规则也称分类模型(Classification Model),分类模型和每个主要性能——是描述性建模,即作为解释性的工具,用于区分不同类别的对象,二是预测性建模,即用于预测未知记录的类标号。

8.1.2 分类的原理

分类方法是一种根据输入数据集建立分类模型的系统方法,这些方法都是使用一种学习算法(Learning Algorithm)确定分类模型,使该模型能够很好地拟合输入数据中类标号和属性集之间的联系。学习算法得到的模型不仅要很好地拟合输入数据,还要能够正确地预测未知样本的类标号。因此,训练算法的主要目标就是建立具有很好泛化能力的模型,即建立能够准确地预测未知样本类标号的模型。

图 8-1 展示了解决分类问题的一般方法。首先,需要一个训练集,它由类标号已知的记录组成。使用训练集建立分类模型,该模型随后将运用于检验集(Test Set),检验集由类标号未知的记录组成。




图 8-1 分类原理示意图

构造模型的过程一般分为训练和测试两个阶段。在构造模型之前,要求将数据集随机地分为训练数据集和测试数据集。在训练阶段,使用训练数据集,通过分析由属性描述的数据库元组来构造模型,假定每个元组属于一个预定义的类,由一个称作类标号属性的属性来确定。训练数据集中的单个元组也称作训练样本,一个具体样本的形式可为: $(u_1, u_2, \dots, u_n, c)$; 其中 u_i 表示属性值, c 表示类别。由于提供了每个训练样本的类标号,该阶段也称为有指导的学习,通常,模型用分类规则、判定树或数学公式的形式提供。在测试阶段,使用测试数据集来评估模型的分类准确率,如果认为模型的准确率可以接受,就可以用该模型对其他数据元组进行分类。一般来说,测试阶段的代价远远低于训练阶段。

任何方法可用 SHAP 大语言模型 知识库记忆 知识库辅助 人类辅助的模型

为了提高分类的准确性、有效性和可伸缩性,在进行分类之前,通常要对数据进行预处理,包括:

- 1) 数据清理。其目的是消除或减少数据噪声,处理空值。
- 2) 相关性分析。由于数据集中的许多属性可能与分类任务不相关,若包含这些属性可能将减慢和误导学习过程。相关性分析的目的就是删除这些不相关或冗余的属性。
- 3) 数据变换。数据可以概化到较高层概念。比如,连续值属性“收入”的数值可以概化为离散值:低,中,高。又比如,标称值属性“市”可概化到高层概念“省”。此外,数据也可以规范化,规范化将给定属性的值按比例缩放,落入较小的区间,比如[0,1]等。

8.1.3 常用的分类方法

分类的方法有多种,常用的分类方法主要有 7 种,如图 8-2 所示。在随后的内容中,将分类介绍这 7 种分类方法的基本原理及典型的应用案例。

8.2 K-近邻

8.2.1 K-近邻原理

K-近邻(K-Nearest Neighbor, KNN)算法是一种基于实例的分类方法,最初由 Cover 和 Hart 于 1968 年提出,是一种非参数的分类技术。

K-近邻分类方法通过计算每个训练样例到待分类样品的距离,取和待分类样品距离最近的 K 个训练样例, K 个样品中哪个类别的训练样例占多数,则待分类元组就属于哪个类别。使用最近邻确定类别的合理性可用下面的谚语来说明:“如果走像鸭子,叫像鸭子,看起来还像鸭子,那么它很可能就是一只鸭子”,如图 8-3 所示。最近邻分类器把每个样例看作 d 维空间上的一个数据点,其中 d 是属性个数。给定一个测试样例,我们可以计算该测试样例




图 8-2 常用的分类方法

图 8-3 KNN 方法原理示意图

可解释性的含义

与训练集中其他数据点的距离（邻近度），给定样例 z 的 K -最近邻是指找出和 z 距离最近的 K 个数据点。

图 8-4 给出了位于圆圈中心的数据点的近邻中含有多个类标号，则将该数据点指派到其最近邻的多数类。在图 8-4a 中，数据点的 1-最近邻是一个负例，因此该点被指派到负类。如果最近邻的多数类，如图 8-4c 所示，其中包括两个正例和一个负例，根据多数表决方案，该点被指派到正类。在最近邻中正例和负例个数相同的情况下（如图 8-4b 所示），可随机选择一个类标号来分类该点。



图 8-4 一个实例的 1-最近邻、2-最近邻和 3-最近邻

KNN 算法具体步骤如下：

- 步骤 1：初始化距离为最大值。
- 步骤 2：计算未知样本和每个训练样本的距离 $dist$ 。
- 步骤 3：得到目前 K 个最近邻样本中的最大距离 $maxdist$ 。
- 步骤 4：如果 $dist$ 小于 $maxdist$ ，则将该训练样本作为 K -最近邻样本。
- 步骤 5：重复步骤 2~步骤 4，直到未知样本和所有训练样本的距离都算完。
- 步骤 6：统计 K 个最近邻样本中每个类别出现的次数。
- 步骤 7：选择出现频率最大的类别作为未知样本的类别

根据 KNN 算法的原理和步骤可以看出，KNN 算法对 K 值的依赖较高，所以 K 值的选择非常重要。如果 K 太小，预测目标容易产生变动性；相反，如果 K 太大，最近邻分类器可能会误分类测试样例，因为最近邻列表中可能包含远离其近邻的数据点（见图 8-5）。推定 K 值的有益途径是通过有效参数的数目这个概念，有效参数的数目是和 K 值相关的，大致等于 n/K ，其中， n 是这个训练数据集中实例的数目。在实践中往往通过若干次实验来确定 K 值，取分类误差率最小的 K 值。




图 8-5 K 较大时的 K -最近邻分类

8.2.2 K-近邻实例

首先先来介绍一下实例的背景：一家银行的工作人员通过电话调查客户是否会愿意

购买一种产品。

属性
Age
Job
Mar
Edu
Def
Bal
Hc
La
C

混淆矩阵

	实际正例	实际负例
预测正例	TP	FP
预测负例	FN	TN

T: true 真
F: false 假
P: Positive 正
N: Negative 负

$$Brier R = \frac{TP}{TP+FN}$$

$$A = \frac{TP+TN}{TP+TN+FP+FN}$$

$$P = \frac{TP}{TP+FP}$$


朴素贝叶斯特点

- 1) 简单、高效、健壮。面对孤立的噪声点，朴素贝叶斯分类器是健壮的，因为在从数据中估计条件概率时，这些点被平均，另外朴素贝叶斯分类器也可以处理属性值遗漏问题。面对无关属性，该分类器依然是健壮的，因为如果 X_i 是无关属性，那么 $P(X_i|Y)$ 几乎变成了均匀分布， X_i 的类条件概率不会对总的后验概率的计算产生影响。
- 2) 相关属性可能会降低朴素贝叶斯分类器的性能，因为对这些属性，条件独立的假设已不成立。

① KNN



② 决策树



神经网络

神经网络原理

神经网络是分类技术中重要方法之一。人工神经网络（Artificial Neural Network, ANN）是一种应用类似于大脑神经突触联接的结构进行信息处理的数学模型。在这种模型中，大量的节点（或称“神经元”，或“单元”）之间相互联接构成网络，即“神经网络”，以达到处理信息的目的。神经网络通常需要进行训练，训练的过程就是网络进行学习的过程。训练改变了网络节点的连接权的值使其具有分类的功能，经过训练的网络就可用于对象的识别。神经网络的优势在于：①可以任意精度逼近任意函数；②神经网络方法本身属于非线性模型，能够适应各种复杂的数据关系；③神经网络具备很强的学习能力，使它能比很多分类算法更好地适应数据空间的变化；④神经网络借鉴人脑的物理结构和机理，能够模拟人脑的某些功能，具备“智能”的特点。

③ 神经网络

人工神经网络（ANN）的研究是由试图模拟生物神经网络而激发的。人类的大脑主要由称为神经元（Neuron）的神经细胞组成，神经元通过叫作轴突（Axon）的纤维丝连在一起。当神经元受到刺激时，神经脉冲通过轴突从一个神经元传到另一个神经元。一个神经元通过树突（Dendrite）连接到其他神经元的轴突，树突是神经元细胞的延伸物。树突和轴突的连接点叫作神经键（Synapse）。神经学家发现，人的大脑通过同一个脉冲反复刺激下改变神经元之间的神经键连接强度来进行学习。




图 8-8 感知器结构示意图

类似于人脑的结构，ANN 由一组相互连接的节点和有向链构成。本节将分析一系列 ANN 模型，从介绍最简单的模型——感知器（Perceptron）开始，看看如何训练这种模型来解决分类问题。

图 8-8 展示了一个简单的神经网络结构——感知器。感知器包含两种节点：几个输入节

指标和手连接, 必须把附件金额款作, 需要减少误报FP, 增加

3) False Positive (FP): 指模型预测为正(1)的, 但是实际上是负(0)的观察对象的数量。

癌症筛查, 需要减少 FN 增加

4) False Negative (FN): 指模型预测为负(0)的, 但是实际上是正(1)的观察对象的数量。

上述4个基本定义可以用一个表格形式简单地体现, 如表8-2所示。

基于上面的4个基本定义, 可以延伸出下列评价指标:

1) Accuracy (正确率): 模型总体的正确率, 是指模型能正确预测、识别1和0的对象数量与预测对象总数的比值, 公式如下:

表 8-2 二类问题的混淆矩阵

实际的类 \ 预测的类	类 1	类 0
类 1	TP	FN
类 0	FP	TN

分类的基本概念与逻辑

分类的定义

对现有数据进行学习，得到一个目标函数或模型（分类器），该模型能把未知类别的样本映射到给定的类别中。

几个基本概念

分类器

能解释原始数据、预测新数据的模型

训练集

用来训练模型的原始数据（划分出一部分）

类标签

数据中已标记的类别

测试集

用来测试模型的数据

开放集

使用训练好的模型进行分类的新数据

交叉验证

划分训练/测试集的方法


分类算法的基本逻辑

原始数据 → 划分训练集/测试集 → 训练分类器 → 测试模型 → 预测新数据

注意：分类是一种预测，不是肯定的，不能期待准确率达到100%，但应比较选出准确率最高的模型

基于统计的学习原理：算法从历史数据中把握特征，形成可应用的预测模型

分类算法总览



KNN算法：思想与步骤

核心思想：物以类聚

"鸭子像鸭子"——与谁为伍就像谁

KNN是最简单的分类算法

基于数据经验（不需要数学模型）

KNN的特殊性

没有显式的分类器（数学模型）

训练集就是它的"模型"

懒惰学习：预测时才计算距离

可以较好地避免数据不平衡问题

算法四步骤（重点）

1 计算距离

计算待分类样品到每个训练样例的距离

2 取k个邻居

取距离最近的k个训练样例

3 统计

k个邻居中哪类占多数

4 投票

待分类样品归属于多数类别

K值选择：k太小→对噪声敏感；k太大→邻居中数量多的样本主导投票，导致误判

KNN与少量相邻样本有关，少数样本密集的情况下KNN效果较好

混淆矩阵（考点）

混淆矩阵结构

实际\预测	正例(P)	负例(N)
	TP	FN
实际正例	TP	FN
实际负例	FP	TN

关键评价指标

准确率 Accuracy

$$(TP+TN)/(TP+FN+FP+TN)$$

精确率 Precision

$$TP/(TP+FP)$$

召回率 Recall

$$TP/(TP+FN)$$

F1值

$$2 \times P \times R / (P + R)$$

业务场景决定指标偏好

垃圾邮件/金融欺诈：减少误报FP → 重点提高精确率P

癌症筛查：减少漏报FN → 重点提高召回率R

不同类型错误（FP/FN）的代价不同，需根据业务权衡

决策树 + 信息增益

决策树概述

一种用来表示做出决策而进行的一系列判断过程的树形图

自顶向下、递归、各个击破的方式构造

最具有可解释性的分类算法

升级版：随机森林（集成算法）

信息增益（核心考点）

根节点的选择→哪属性最重要

信息增益 $\text{Gain}(A)=I(s_1, s_2, \dots, s_m)-E(A)$

$I(s_1, s_2, \dots, s_m)=-\sum p_i \log_2(p_i)$ 类别熵

$E(A)=\sum (s_{1j} + \dots + s_{mj})/s \times I(s_{1j}, \dots, s_{mj})$ 条件熵

信息增益越大 → 属性越重要 → 越靠根节点

示例：打高尔夫球（ID3算法）

14个样本，4个属性：outlook(天气)/temperature(温度)/humidity(湿度)/windy(风)

类别：P(适合打球)=9, N(不适合)=5

$I(p,n)=-9/14 \times \log_2(9/14)-5/14 \times \log_2(5/14)=0.940$

$E(\text{outlook})=5/14 \times I(2,3)+4/14 \times I(4,0)+5/14 \times I(3,2)=0.694$

$\text{gain}(\text{outlook})=0.940-0.694=0.246$ （最大→根节点为outlook）

$\text{gain}(\text{temperature})=0.029$ | $\text{gain}(\text{humidity})=0.151$ | $\text{gain}(\text{windy})=0.048$

递归确定子节点，直到所有样本属于同一类或属性用完

神经网络（感知器）

感知器：神经网络的基本单元

输入 → 加权求和 → 阈值判断 → 输出

外部因素 $x=(x_1, x_2, x_3)$

权重 $w=(w_1, w_2, w_3)$

运算： $w \cdot x = \sum wx$ (点积)

阈值 b : $w \cdot x + b > 0 \rightarrow$ 输出1, 否则0

示例：小明参观动漫展

天气权重8 + 同伴权重4 + 价格权重4, 阈值=8

天气(1)×8 + 同伴(1)×4 + 价格(1)×4 = 16 > 8 → 去!

神经网络的训练过程

搭建神经网络需要三条件：

- ① 输入和输出
- ② 权重 w 和阈值 b
- ③ 多层感知器的结构

试错法训练

参数微小变动 $\Delta w/\Delta b$, 观察输出变化

反复迭代直到找到最精确的 w 和 b

基于梯度下降的优化过程

三层神经网络结构



| 朴素贝叶斯方法

基本思想

对于待分类项，求解在此项出现的条件下
各个类别出现的概率，哪个最大就属于哪类

贝叶斯定理

$$P(Y|X) = P(X|Y) \cdot P(Y) / P(X)$$

条件独立假设 $\rightarrow P(X|Y) = \prod P(x_i|Y)$

朴素贝叶斯的特点

- ✓ 逻辑简单，公式转换后只需统计历史数据
- ✓ 条件独立假设 + 中心极限定理 = 降低复杂度
- ✗ 特征往往很难完全独立 $\rightarrow$ 影响准确性

案例：求婚决策

特征：不帅·性格不好·矮·不上进

判断：嫁还是不嫁？

$$P(\text{嫁}) = 1/2$$

$$P(\text{不帅}|\text{嫁}) = 1/2, P(\text{性格不好}|\text{嫁}) = 1/6$$

$$P(\text{矮}|\text{嫁}) = 1/6, P(\text{不上进}|\text{嫁}) = 1/6$$

$$P(\text{嫁}|X) = 1/2 \times 1/2 \times 1/6 \times 1/6 \times 1/6 = 1/864$$

$$P(\text{不嫁}|X) = 1/2 \times 1/3 \times 1/2 \times 1 \times 2/3 = 1/18$$

$$P(\text{嫁}|X) = 1/864 \div (1/864 + 1/18) = 2.04\%$$

$$P(\text{不嫁}|X) = 1/18 \div (1/864 + 1/18) = 97.96\%$$

结论：不嫁！

第三次作业总结

分类算法 · 课后作业核心内容

✓ 分类的基本概念与逻辑

分类器·训练集·测试集·类标签·交叉验证
训练→测试→预测的基本流程

✓ KNN算法

计算距离→选k个邻居→统计→投票
k值选择·混淆矩阵·准确率/精确率/召回率

✓ 决策树

ID3算法·信息增益·高尔夫示例
根节点选择→递归构造子节点→剪枝防过拟合

✓ 神经网络 + Bayes

感知器：输入×权重→阈值判断→输出
朴素贝叶斯：后验概率最大→分类

读书笔记：《白话机器学习》第7章KNN + 第9章决策树

KNN最简·基于邻居投票·决策树可解释性强·树形分叉·随机森林集成决策树提升性能
不同算法对同一问题可以探索和比较，根据业务场景选择最优分类器

分类本质：历史数据中学习模式 → 预测未知样本类别