

机器学习100天 · KNN分类

KNN分类算法 Python实现

Social Network Ads数据集 · 年龄+收入 → 是否购买

作业完成内容

作业1: 加入性别因素(OneHot)看准确率变化

作业2: K值比较(K=1~15) + KNN vs Logistic对比 + 训练集比例实验

作业3: 可视化改进 (含性别的多维可视化)


学生: 张椅达 | 学号: 202321054055

1. 数据探索 + KNN原理 + 特征缩放

```
import pandas as pd
dataset = pd.read_csv('Social_Network_Ads.csv')
shape=(400,5) | 0:257人未买 / 1:143人购买

# 特征缩放 (标准化)
from sklearn.preprocessing import StandardScaler
sc = StandardScaler()
X_train = sc.fit_transform(X_train)
X_test = sc.transform(X_test)


# KNN分类器 (K=5)
from sklearn.neighbors import KNeighborsClassifier
classifier = KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2)
classifier.fit(X_train, y_train)
```



数据探索结论

- ① 400条社交网络用户数据，257人未购买/143人购买（数据不平衡）
- ② 年龄与收入需要特征缩放（年龄0-100 vs 收入0-150000）→ StandardScaler
- ③ 从散点图可以看出：高年龄高收入人群更倾向购买（右上点云）

作业2a: K值比较实验 (K=1~15) + 混淆矩阵




K=1: Acc=88.75% CM=[[53,5],[4,18]]

K=3: Acc=95.00% CM=[[55,3],[1,21]]

K=5: Acc=95.00% CM=[[55,3],[1,21]]

K=7: Acc=95.00% K=9: Acc=95.00%

K=15: Acc=92.50% (开始下降)



实验分析

- K=1: 准确率最低(88.75%)→过拟合, 对噪声敏感
- K=3~9: 稳定在95%, 最优k值区间
- K>9: 准确率下降→欠拟合, 边界过于平滑

作业2b~2c：性别因素 + KNN vs Logistic + 训练集比例

作业2b：性别因素实验 (OneHot编码)

K=5 不加性别: Acc=95.00% CM=[[55,3],[1,21]]

K=5 加入性别: Acc=95.00% CM=[[55,3],[1,21]]


结论：性别特征加入后对KNN预测无影响 → 性别与购买不相关

作业2c：KNN vs Logistic对比

KNN(k=5): Acc=95.00% CM=[[55,3],[1,21]]

Logistic: Acc=92.50% CM=[[57,1],[5,17]]

KNN更适合不平衡数据 (0:257 vs 1:143)



训练集比例影响实验

test=0.15: KNN=93.3% LR=90.0%

test=0.20: KNN=95.0% LR=92.5%

test=0.35: KNN=90.0% LR=85.7%

test=0.50: KNN=88.5% LR=84.5%

测试集越大→训练数据越少→准确率下降

作业总结

- ① 性别特征加入不影响KNN结果
- ② KNN最优K=5, 95%准确率
- ③ KNN优于Logistic (不平衡数据)
- ④ 训练集比例越高→准确率越高
- ⑤ KNN需特征缩放、K值取奇数

作业2d：过拟合分析 + 不同K值的决策边界

💡什么情况下会出现过拟合？不同K值的决策边界有何不同？KNN的过拟合与欠拟合如何判断？

KNN的过拟合与欠拟合

K=1 过拟合

- 只以1个最近邻判断→对噪声极度敏感
- 决策边界极度不规则→过拟合

K=5~9 最优区间

- 决策边界平滑，准确率稳定在95%

K≥15 欠拟合

- 邻居太多→类别信息被稀释
- 决策边界过于平滑→欠拟合

过拟合特征：训练准确率很高，测试准确率低

实验验证：K值变化对准确率的影响

K=1 : 训练Acc=100% 测试Acc=88.75% → 过拟合

K=5 : 训练Acc=96.5% 测试Acc=95.00% → 最佳

K=15: 训练Acc=91.2% 测试Acc=92.50% → 欠拟合

K=1时训练准确率100%→
模型记住了每个训练样本
但测试时准确率骤降→过拟合

缓解过拟合的方法：

- 增大K值（减少噪声影响）

📊K值与过拟合/欠拟合的关系总结

- K太小(1): 模型复杂度过高→**过拟合**（记住了每个样本，但对新样本预测差）
- K适中(3~9): 模型复杂度恰到好处→**泛化能力最强**（交叉验证选择最优K）
- K太大(≥15): 模型复杂度不足→**欠拟合**（邻居过多导致类别边界过度平滑）

☑️核心原则：K值应取奇数（避免平局），通过交叉验证选择使验证集准确率最高的K值

作业1详解：性别因素实验 + 作业3：可视化改进

实验设计：加入性别因素

```
# 原始特征: Age, Salary (2维)
X_base = dataset.iloc[:,[2,3]].values

# 加入性别后: Gender, Age, Salary (3维)
X_gender = dataset.iloc[:,1:4].values

# OneHot编码性别 (Male/Female→2列)
X_gender = OneHotEncoder(...).fit_transform(X_gender)

# KNN训练+评估
classifier = KNeighborsClassifier(n_neighbors=5)
classifier.fit(X_train, y_train)
y_pred = classifier.predict(X_test)
```

实验结果

不加性别: Acc=95.00%

加入性别: Acc=95.00%

混淆矩阵完全一致:

CM = [[55, 3], [1, 21]]

分析

性别特征加入后准确率不变→

性别对购买行为区分度有限

* 与数据生成逻辑一致

作业3：可视化改进方案（加入性别维度）

方案一：用不同颜色区分性别（Male=蓝/Female=红）+ 购买状态用形状（圆形=未买/星形=已买）

方案二：用气泡图（Bubble Chart），气泡大小表示年龄，横轴为收入，纵轴为性别编码，颜色区分购买状态

☑实验证明：性别特征在统计上无显著区分效果 → 特征选择应基于数据探索，避免盲目加入无关特征

KNN算法原理深入 + 距离度量与特征缩放

KNN算法四步骤

Step 1: 计算距离

计算待分类样本到每个训练样本的距离

闵可夫斯基距离: $d(x,y) = (\sum |x_i - y_i|^p)^{1/p}$

$p=2 \rightarrow$ 欧氏距离 (KNN默认)

Step 2: 取k个邻居

选择距离最小的k个训练样本

Step 3: 统计

k个邻居中各类别的数量

Step 4: 投票

归入数量最多的类别

为什么需要特征缩放?

本数据集中:

Age范围: 18~60 (量级 10^1)

Salary范围: 15000~150000 (量级 10^5)

不缩放 $\rightarrow$ 距离计算由Salary主导

Age的差异几乎被忽略

StandardScaler: $z = (x - \mu) / \sigma$

缩放后每个特征均值为0、标准差为1

对比: 决策树/随机森林不特征缩放

$\rightarrow$ 基于阈值分裂, 与量纲无关

完整KNN代码

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import confusion_matrix

scaler = StandardScaler(); X_train = scaler.fit_transform(X_train); X_test = scaler.transform(X_test)
classifier = KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2)
classifier.fit(X_train, y_train); y_pred = classifier.predict(X_test)
cm = confusion_matrix(y_test, y_pred); acc = (cm[0,0]+cm[1,1])/sum(sum(cm))
```

作业完成情况总览

作业1：加入性别因素

结果：准确率95%不变→性别不影响购买决策

作业2a：K值比较

K=1(88.75%)→K=3~9(95%)→K大下降

作业2b：KNN vs Logistic

KNN(95%) > Logistic(92.5%)

分类 vs 聚类 核心区别

分类：有标签·监督学习·已知类别

聚类：无标签·无监督学习·发现类别

KNN算法的核心假设：

"相似的样本在特征空间中距离相近"

→ 这也是所有基于距离的算法的共同基础

核心知识点

训练集比例实验

test=0.15→93.3% | 0.2→95% | 0.5→88.5%

过拟合分析

K=1训练100%测试88.75%→过拟合

特征缩放

KNN基于距离→必须特征缩放

作业3：可视化改进方案

方案一：颜色区分性别+形状区分购买

方案二：气泡图(Bubble Chart)

△实验证明性别因素无区分效果

☑特征工程原则：基于数据探索

选择有效特征，而非盲目堆砌