

机器学习


决策树 Decision Tree

作业完整解析报告


- ▶ 作业1: 加入性别特征的影响
- ▶ 作业2: 特征缩放的必要性分析
- ▶ 作业3: 三模型横向对比
- ▶ 作业4: 决策树结构可视化

作业 1：加入性别特征，准确率如何变化？

作业1：加入性别特征后的准确率变化



混淆矩阵 (加入性别特征)



◆ 特征工程的取舍至关重要：并非特征越多越好

Gender → LabelEncoder(Female=0, Male=1) → 与 Age, Salary 一起标准化后输入决策树

分析结论

基准准确率

68.75%

加入性别后

65.00%

变化幅度

-3.75%


性别特征引入后准确率略降

说明性别对购买行为区分度有限（与数据生成逻辑一致）


过多无关特征可能导致过拟合，降低泛化能力

作业 2：不进行特征缩放，预测准确性有何变化？

作业2：特征缩放 vs 不缩放



有缩放 - 混淆矩阵



实验结论

有特征缩放

68.75%

无特征缩放

68.75%

准确率变化

0.00%

✓ 决策树 / 随机森林 → 不需要特征缩放


✓ KNN / SVM / Logistic Regression → 必须特征缩放

决策树基于特征的阈值进行分裂，与特征的量纲无关！

对比：KNN/SVM/LR等基于距离或梯度的模型则必须进行特征缩放

作业 3： KNN vs Logistic Regression vs Decision Tree

作业3：KNN vs Logistic Regression vs Decision Tree 准确率对比






模型	准确率	优势	劣势
KNN (k=5)	63.75%	简单无参数	计算慢，需缩放
Logistic Reg.	67.50%	可解释性强	线性边界限制
Decision Tree	68.75%	无需缩放/可视化	易过拟合

📌 本数据集上，Decision Tree 准确率最高 (68.75%)

三种模型的决策边界可视化对比

三种模型决策边界对比



KNN

边界不规则，受局部样本影响大，k值敏感

Logistic


线性决策边界，无法拟合非线性结构

Decision Tree

矩形分割边界，能捕捉非线性，但可能过拟合

作业 4：决策树结构可视化（max_depth=3, criterion=entropy）

作业4：决策树结构可视化 (max_depth=3, criterion=entropy)



entropy

当前节点的信息熵，越接近0越纯

samples

该节点包含的样本数

value=[a,b]

各类别样本数 [未购买, 购买]

class

该节点的预测类别

作业总结与知识收获

作业1：性别特征

65.00%

加入后准确率下降3.75%，无关特征引入噪声，特征工程需谨慎选择

作业2：特征缩放

68.75%

有无缩放准确率完全相同，决策树基于阈值分裂，不受量纲影响

作业3：模型对比

DT最优

Decision Tree > Logistic(67.5%) > KNN(63.75%)，不同模型边界形状各异

作业4：树结构

深度3层

通过entropy分裂，可视化节点包含：熵值、样本数、各类别数、预测类

决策树是可解释性强、无需特征缩放的高效分类器，但需注意过拟合风险（可通过限制深度或使用随机森林缓解）