

# 《白话机器学习算法》

## 读书笔记

参考教材3 · 全书12章·63页详细笔记

作者: [新加坡]黄莉婷 苏川集 · 译者: 武传海

学生: 张椅达 | 学号: 202321054055

# 目录

## 第1章 基础知识

数据准备·算法选择·参数调优·评价

全书基础 P03-P07

## 第2章 k均值聚类

找出顾客群·定义群组

无监督学习 P08-P12

## 第3章 主成分分析

降维·主成分提取

无监督学习 P13-P17

## 第4章 关联规则

支持度·置信度·提升度

无监督学习 P18-P22

## 第5章 社会网络分析

Louvain·PageRank

无监督学习 P23-P27

## 第6章 回归分析

梯度下降·回归系数

监督学习 P28-P32

## 第7章 KNN与异常检测

最近邻·异常值

监督学习 P33-P37

## 第8章 支持向量机

最大间隔·核技巧

监督学习 P38-P42

## 第9章 决策树

树形结构·特征分裂

监督学习 P43-P47

## 第10章 随机森林

集成学习·Bagging

监督学习 P48-P52

## 第11章 神经网络

多层感知机·激活函数

监督学习 P53-P57

## 第12章 A/B测试与MAB


epsilon递减·强化学习

强化学习 P58-P62

每章包含：思维导图 → 核心原理 → 原书图文 → 应用场景 → 局限性·小结，共4-5页

# 基础知识

## 第1章 知识体系思维导图



### 1.1 准备数据

数据格式 (行=观测, 列=变量)  
变量类型 (二值·分类·整型·连续)  
特征工程·缺失数据处理

### 1.2 选择算法

无监督学习 (发现隐藏模式)  
监督学习 (做预测)  
强化学习 (根据反馈改进)

# 1.1 准备数据

表格格式：每一行是一个数据点（观测），每一列是一个变量

## 四种变量类型

### 二值变量

只有两种可能的值  
如"是否买鱼": 是/否

### 分类变量

可取两个以上的值  
如"顾客类别": 兔子/猫/狗

### 整型变量

用整数表示  
如"水果购买"

## 三种缺失值处理方法

### 近似

二值/分类用众数替换，整型/连续用中位数

### 计算

用监督学习算法估算缺失值（更准确）

### 移除

万不得已时移除整行（会减少数据量）

## 特征工程

将原始变量重编码为更有用的变量。例如：将"猫、兔子、狗"重编码为"食肉动物、食草动物"。降维(PCA)也是特征工程的手段。

如果数据的质量差，那么分析得再精确也只能得到平淡无奇的结果。——原书

| 变量   |      |       |       |      |        |
|------|------|-------|-------|------|--------|
| 交易编号 | 顾客类别 | 日期    | 水果购买量 | 是否买鱼 | 支出     |
| 1    | 企鹅   | 01/01 | 1     | 是    | 5.30美元 |
| 2    | 熊    | 01/01 | 4     | 是    | 9.70美元 |
| 3    | 兔子   | 01/01 | 6     | 否    | 6.50美元 |
| 4    | 马    | 01/02 | 6     | 否    | 5.50美元 |
| 5    | 企鹅   | 01/02 | 2     | 是    | 6.00美元 |
| 6    | 长颈鹿  | 01/03 | 5     | 否    | 4.80美元 |
| 7    | 兔子   | 01/03 | 8     | 否    | 7.60美元 |
| 8    | 猫    | 01/03 | ?     | 是    | 7.40美元 |

## 1.2 选择算法

|       | 算法                                              |
|-------|-------------------------------------------------|
| 无监督学习 | $k$ 均值聚类<br>主成分分析<br>关联规则<br>社会网络分析             |
| 监督学习  | 回归分析<br>$k$ 最近邻<br>支持向量机<br>决策树<br>随机森林<br>神经网络 |
| 强化学习  | 多臂老虎机                                           |

### 无监督学习

指出数据中隐藏的模式

算法： $k$ 均值聚类·PCA·关联规则·社会网络分析

### 监督学习

使用数据中的模式做预测

算法：回归·KNN·SVM·决策树·随机森林·神经网络

### 强化学习

根据越来越多的反馈结果不断改进

算法：A/B测试·多臂老虎机·epsilon递减策略

### 回归 vs 分类

回归问题：预测连续数值（如房价）| 分类问题：预测离散值（如是否下雨）。大部分分类算法也可以生成连续的概率值。

**任务类型决定了算法的选择：想要发现模式还是做预测？**

## 1.3 参数调优

### 过拟合 (Overfitting)

算法过度敏感, 把数据中的随机波动  
错误地当成持久模式

对当前数据准确度高  
对未知数据泛化能力差

原因: 模型过于复杂

对策: 正则化·增加数据·简化模型


### 欠拟合 (Underfitting)

算法过于愚钝  
忽视了数据中的基本模式

对当前数据和未知数据的  
预测准确度均下降

原因: 模型过于简单

对策: 增加特征·提高模型复杂度



(a) 过拟合

(b) 理想拟合

(c) 欠拟合

图1-2 同一个算法在不同参数下的预测结果

### 正则化 (Regularization)

通过引入惩罚参数来控制模型复杂度

惩罚参数会人为增大预测误差

对模型复杂度的增加进行"惩罚"

使算法同时考虑复杂度和准确度

**保持模型简单 → 提高泛化能力**

## 1.4 评价模型 + 本章小结

### 预测准确率

正确的预测所占的比例

公式: 正确预测数/总预测数

优点: 直观易懂

缺点: 无法得知误差产生的类型

### 混淆矩阵

真阳性(TP)·假阳性(FP)

假阴性(FN)·真阴性(TN)

有助于区分不同类型误差

用于计算精确率·召回率·F1值

### RMSE

均方根误差

回归任务中的常用指标

对较大误差给予更高权重

与原变量单位相同

### 验证方法

训练集/测试集划分·交叉验证 (k-fold) ·留出法·自助法

## 第1章小结

### 数据处理

理解数据格式·区分变量类型

特征工程·缺失值处理

### 算法选择

无监督·监督·强化学习


回归问题 vs 分类问题

### 模型优化

过拟合控制·正则化

准确率·混淆矩阵·RMSE

# k均值聚类





## 2.1 算法原理 · 2.2 定义群组

### k均值聚类四步骤

1

#### 确定k值

选择要将数据  
分成多少个群组

2

#### 选择初始质心

随机选取k个点  
作为初始群组中心

3

#### 分配数据点

每个点归入距离  
最近的质心


4

#### 更新质心

重新计算每个  
群组的中心点

重复步骤3-4，直到质心不再变化或达到最大迭代次数 → 算法收敛

### 肘部法则确定k值



#### 肘部法则 (Elbow Method)

绘制SSE (误差平方和) 随k值变化的曲线  
曲线出现拐点 (像"手肘") 的位置 → 最优k值  
拐点处说明再增加k值对降低SSE的效果已不明显  
本质是在群组数量和群组内紧密度之间取舍

## 2.3 示例：影迷的性格特征

情景：一组影迷被问及对不同类型电影的喜好程度（1-5分）。通过k均值聚类将他们分成不同群组。

数据来源：原书第2章示例数据集

### 聚类结果 (k=3)

#### 群组A：文艺片爱好者

喜欢：艺术片、纪录片

不喜欢：商业大片、动作片

→ 推荐文艺片和纪录片

#### 群组B：动作迷

喜欢：动作片、冒险片

不喜欢：爱情片、文艺片

→ 推荐动作冒险大片

#### 群组C：狂热影迷

对所有类型电影评分都很高

无特别偏好，平均评分>4分

→ 可推荐所有类型新片

### 应用价值

#### 个性化推荐

根据影迷所属群组，推荐该群组

喜欢的电影类型 → 提高观影满意度

#### 注意事项

k值的选择影响聚类质量

不同初始质心可能导致不同结果

## | 2.4 局限性 + 第2章小结

### 局限1：需要预先指定k值

必须事先知道要将数据分成多少类，而领域知识可能不足以提供准确的k值

### 局限2：对初始质心敏感

不同的初始质心选择可能导致不同的聚类结果，算法可能收敛到局部最优而非全局最优

### 局限3：只能发现球形群组

k均值假设数据围绕质心呈球形分布，对非凸形状和密度不均的群组聚类效果不佳


### 局限4：受离群点影响

离群点会拉偏质心的位置，影响整体聚类质量，需要先做数据预处理

## 第2章小结

- ✓ k均值聚类是最经典的无监督学习算法，通过迭代优化将数据划分为k个群组
- ✓ 确定k值的常用方法：肘部法则（SSE拐点）、轮廓系数
- ✓ 应用场景包括客户分群、图像压缩、异常检测、个性化推荐
- ✓ 局限性：需预知k值、对初始质心和离群点敏感、仅适合球形群组

## 第2章 · 原书图文与核心概念



原书第2章插图：k均值聚类示意图

### 原书核心观点

"找出顾客群" — 将顾客根据其消费行为划分为不同群组

"定义群组" — 每个数据点归入距离最近的质心所在的群组

k均值通过不断迭代优化

让群组内差异最小化

### 距离度量

欧氏距离是最常用的距离度量

$$d(x, y) = (\sum (x_i - y_i)^2)^{\frac{1}{2}}$$

计算每个点到质心的距离，归入最近的群组

# 主成分分析

PCA

降维原理

应用场景

## 三大应用

数据可视化（降维到2D/3D）  
降噪（舍弃小方差主成分）  
特征提取（减少特征数量）

确定主成分

注意事项

## 使用注意

数据需标准化  
PCA是线性方法  
主成分可解释性有限

## 3.1 PCA原理 · 3.2 主成分提取

PCA（主成分分析）通过提取数据中方差最大的方向（主成分），将高维数据映射到低维空间，在保留数据最主要信息的同时实现降维。

### PCA的核心步骤

1

#### 数据标准化

对每个特征减去均值、除以标准差  
消除量纲对方差的影响

2

#### 计算协方差矩阵


衡量各变量之间的线性相关性

3

#### 特征值分解

计算协方差矩阵的特征值和特征向量  
特征值越大→越重要的主成分

### 主成分的选择



#### 碎石图 (Scree Plot)

绘制各主成分的特征值→找到拐点


保留累积方差贡献率达到85%-95%的前k个主成分

第1主成分 = 方差最大的方向，第2主成分与第1正交

## 3.3 示例：分析食物种类 + 应用场景

### 示例：分析食物种类

每种食物都有热量、蛋白质、脂肪、碳水化合物等多种营养成分指标。这些维度之间存在相关性，直接在高维空间中分析很困难。通过PCA可以将多维指标降至2个主成分，在二维平面中直观观察。



原书第3章插图：食物营养数据的PCA降维结果

### 典型应用

#### 数据可视化

高维数据降到2D/3D  
在平面中展示聚类结构

#### 降噪处理

舍弃方差小的主成分  
保留主要信号去除噪声

#### 特征提取

减少模型输入特征数  
加快训练·缓解维度灾难

#### 人脸识别

特征脸(Eigenface)方法  
提取人脸主成分做识别

## 3.4 局限性 + 第3章小结

### 局限性：PCA是线性方法

PCA只能捕捉线性关系，对于非线性结构的数据，可用t-SNE或自编码器处理

### 局限性：可解释性有限

主成分是原始变量的线性组合，可能没有明确的物理含义


### 第3章小结

- ✓ PCA通过主成分提取实现降维，保留数据中最重要的变异信息
- ✓ 第一主成分是方差最大的方向，后续主成分与之前所有主成分正交
- ✓ 用碎石图和累积方差贡献率确定保留的主成分数量
- ✓ PCA前需做标准化，它是线性方法、主成分可解释性有限


PCA是降维和可视化的利器——化繁为简，但不改变数据的本质结构




## 第3章 · PCA原书图文




步骤1



步骤2



步骤3



步骤4

### 原书内容精要

"食物的营养成分"一例中，多种营养成分指标之间存在相关性

PCA提取的主成分是原始变量的线性组合，彼此之间不相关

### 确定主成分数量的方法

1. Kaiser准则：保留特征值 $>1$ 的主成分
2. 累积方差贡献率：保留85%-95%的主成分
3. 碎石图：观察曲线拐点

PCA不要求数据有标签

属于无监督学习方法

结果可用于后续的监督学习

# 关联规则

关联规则

核心指标

购物篮分析

## 三个核心指标

支持度：项集出现的频率  
置信度：规则的可靠性  
提升度：关联的强度 ( $>1$ 为正相关)

先验原则

局限性

## Apriori局限性

可能生成大量冗余规则  
需合理设置支持/置信度阈值  
经典案例：啤酒与尿布

## 4.1 支持度·置信度·提升度

### 支持度 (Support)

衡量项集X出现的频率

$$\text{Support}(X) = \text{count}(X) / N$$

例: {面包,牛奶}出现在60%的交易中

支持度高 → 该模式常见

### 置信度 (Confidence)

衡量规则A→B的可靠性

$$\text{Conf}(A \rightarrow B) = P(A \wedge B) / P(A)$$

例: 买了面包的顾客中有75%也买了牛奶

置信度高 → 条件概率大

### 提升度 (Lift)

衡量关联的强度

$$\text{Lift}(A \rightarrow B) = \text{Conf} / P(B)$$


Lift > 1 → 正相关 (有价值关联)

Lift = 1 → 独立无关联

### Apriori先验原则

**核心原理: 如果一个项集是非频繁的, 那么它的所有超集都是非频繁的。**

- ① 先生成所有满足最小支持度的频繁项集
- ② 再从频繁项集中生成满足置信度/提升度阈值的关联规则
- ③ 通过剪枝减少候选项集的数量, 大幅降低计算复杂度



## 4.2 示例：杂货店销售 + 局限性

### 购物篮分析示例

#### 交易数据

T1: 面包, 牛奶, 鸡蛋  
T2: 面包, 黄油, 牛奶  
T3: 啤酒, 薯片, 面包  
T4: 面包, 牛奶, 黄油, 鸡蛋

#### 发现规则: {面包} → {牛奶}

支持度:  $3/4 = 75\%$  (面包和牛奶同时出现3次)  
置信度:  $3/4 = 75\%$  (买面包的顾客75%也买了牛奶)  
提升度:  $0.75/0.75 = 1$  (牛奶的总购买频率也是75%)  
→ 可优化货架布局, 将面包和牛奶放在相邻位置

### 局限性


#### 大量冗余规则

支持度和置信度阈值设置不当会生成大量无意义规则

#### 计算复杂度高

大数据集上候选项集数量呈指数级增长

小结: 关联规则发现变量间的共现关系, Apriori利用先验原则剪枝, 经典应用是购物篮分析和交叉销售。



### 关联规则原书要点

关联规则在大规模数据集中  
发现商品之间的有趣关系

典型应用：超市购物篮分析

### 先验原则的作用

如果{面包}不频繁，那么{面包,牛奶}  
{面包,黄油}等所有包含面包的超集  
都不需要再考虑

这个剪枝策略大幅减少了需要  
检查的项集数量

提升度比置信度更可靠

因为它考虑了商品本身的  
基准出现频率

### 第4章 核心要点回顾

#### 关联规则三要素

支持度：项集出现频率，衡量规则的普遍性

置信度：条件概率，衡量规则的可信程度

提升度：实际置信度与期望置信度之比， $>1$ 为正关联

#### Apriori算法精髓

先验原则（Apriori Property）：一个项集若非频繁，其超集必非频繁

两步走：先找频繁项集，再从中提取关联规则

#### 局限性

可能生成大量冗余规则，阈值的设置需要领域知识

高置信度不一定代表有意义的关联（需结合提升度判断）

数据集稀疏时Apriori的效率较低

关联规则发现“啤酒与尿布”式的隐藏关系，帮助商家理解消费者的购买行为模式

# 社会网络分析

社会网络

Louvain

## Louvain社区发现

目标：划分内部紧密的社区

原理：最大化模块度(Modularity)

应用：社交兴趣小组发现

## PageRank排名算法

目标：衡量节点重要性

原理：随机游走+链接分析

应用：Google搜索引擎核心算法

PageRank

## 5.1 Louvain方法 + 5.2 PageRank

### Louvain 社区发现

将网络划分为内部紧密连接的社区

核心指标：模块度 (Modularity)

量化社区划分质量——社区内边数 vs 随机边数

#### 算法步骤

1. 每个节点初始属于不同社区
2. 遍历节点，移到使模块度增益最大的邻居社区
3. 将发现社区合并为新节点，重复迭代

### PageRank 排名算法

衡量节点在网络中的重要性

核心思想：被越多重要节点链接→越重要


Google搜索引擎的起家算法

#### 原理

在网络上随机游走 (Random Walk)

统计访问各节点的频率作为重要性

迭代计算直至分数收敛



### 示例：国际贸易网络

以国家为节点、贸易关系为边构建网络


Louvain → 发现区域贸易集团 (如欧盟、东盟)

PageRank → 找出最具影响力的贸易大国

局限性：网络数据获取困难

大规模网络计算复杂度高





## 原书要点：展现人际关系

社会网络分析用图结构表示  
实体（节点）及其关系（边）

## Louvain vs PageRank

Louvain：发现社区（群组划分）

PageRank：排名（重要性评估）

两者结合：既知道社区归属  
又知道谁是最有影响力的节点

## 应用场景

社交网络中的兴趣小组发现

搜索引擎结果排序（PageRank）

生物信息学中的蛋白质交互网络

反欺诈：识别金融交易网络中的异常

## | 第5章 · 局限性 + 小结

### 数据获取困难

网络数据涉及隐私，获取完整的网络关系数据往往具有挑战性

### 计算复杂度高

大规模网络包含百万级节点，需要高效的计算方法

## 第5章 小结

- ✓ 社会网络分析用图结构表示实体之间的关系
- ✓ Louvain方法通过优化模块度发现网络中的社区结构
- ✓ PageRank通过随机游走衡量节点在网络中的重要性
- ✓ Google搜索引擎的核心算法建立在PageRank之上
- ✓ 两种方法互补：Louvain发现群组，PageRank评估个体影响力
- ✓ 应用：社交网络、推荐系统、反欺诈、生物信息学

# 回归分析

趋势线

梯度下降

回归分析

回归系数

相关系数

## 核心知识点

- 回归建立自变量与因变量的定量关系，预测连续数值结果
- 梯度下降法：沿误差函数负梯度方向迭代调整回归系数
- 回归系数表示自变量每变化单位，因变量的变化量
- $R^2$  决定系数衡量模型拟合优度，越接近1解释力越强
- 示例：用面积、卧室数预测房价

## 6.1 梯度下降法 + 6.2 回归系数

### 梯度下降 (Gradient Descent)

优化回归系数的核心算法

沿误差函数 (MSE) 的负梯度方向迭代

逐步调整系数  $w$ , 使预测误差最小化

#### 学习率

决定每次更新的步长大小

太大: 可能越过最优解

太小: 收敛速度很慢

### 回归系数与 $R^2$

简单线性回归:  $y = wx + b$

$w$  = 回归系数 (斜率)

$b$  = 截距

#### 相关系数 ( $R^2$ )

衡量模型拟合优度  $[0,1]$

$R^2=0.8 \rightarrow$  自变量解释80%的因变量变异

越接近1  $\rightarrow$  模型解释力越强

|       | 主成分 1 | 主成分 2 | 主成分 3 | 主成分 4 |
|-------|-------|-------|-------|-------|
| 脂肪    | -0.45 | 0.66  | 0.58  | 0.18  |
| 蛋白质   | -0.55 | 0.21  | -0.46 | -0.67 |
| 膳食纤维  | 0.55  | 0.19  | 0.43  | -0.69 |
| 维生素 C | 0.44  | 0.70  | -0.52 | 0.22  |

### 示例: 预测房价

自变量: 面积、卧室数、位置评分

因变量: 房价

模型: 房价 =  $w_1 \times \text{面积} + w_2 \times \text{卧室数} + w_3 \times \text{位置评分} + b$

局限性: 线性假设、对异常值敏感、多重共线性

## | 第6章 · 局限性 + 小结

### 局限性

#### 线性假设

假设自变量与因变量之间存在线性关系

#### 异常值敏感

离群点会显著影响回归系数的估计

#### 多重共线性

自变量之间高度相关时，系数估计不稳定

#### 仅能预测连续值

分类问题需要使用Logistic回归等其他方法

### 第6章 小结

- ✓ 回归分析预测连续数值目标变量
- ✓ 梯度下降通过迭代优化回归系数
- ✓  $R^2$ 决定系数衡量模型的解释力
- ✓ 学习率的选择直接影响梯度下降的收敛效果

|       | 主成分 1 | 主成分 2 | 主成分 3 | 主成分 4 |
|-------|-------|-------|-------|-------|
| 脂肪    | -0.45 | 0.66  | 0.58  | 0.18  |
| 蛋白质   | -0.55 | 0.21  | -0.46 | -0.67 |
| 膳食纤维  | 0.55  | 0.19  | 0.43  | -0.69 |
| 维生素 C | 0.44  | 0.70  | -0.52 | 0.22  |

### 原书要点

"趋势线"——回归在数据点中  
拟合出最能代表整体趋势的直线

### 关于梯度下降

初始设定随意（起点不重要）  
算法通过试错迭代改善  
每次微调使误差变小  
最终收敛到最优解

### 回归分析常见算法

简单线性回归：1个自变量  
多元线性回归：多个自变量  
Logistic回归：分类问题用的回归  
多项式回归：拟合曲线关系

# k最近邻算法与异常检测

物以类聚

距离度量

KNN

异常检测

## 核心知识点

- KNN通过找出最近的k个邻居来分类（监督）或识别异常（无监督）
- k值是核心超参：k太小→过拟合对噪声敏感，k太大→决策边界过分平滑
- 常用的距离度量：欧氏距离、曼哈顿距离、余弦相似度
- 异常检测：离所有邻居都很远的点可能是异常值（欺诈检测、故障预警）
- KNN是懒惰学习（Lazy Learning）：不需要训练过程但预测时计算全部距离

## 7.1 KNN原理 + 示例：区分红白葡萄酒

### KNN分类原理

- ① 计算新数据点到所有已知点的距离
- ② 选出距离最小的k个邻居
- ③ k个邻居中多数类别→分类结果

### k值的选择

k=1 → 噪声敏感（过拟合）

k越大→边界越平滑（欠拟合风险）

通常取奇数避免平局，交叉验证选最优

### 示例：区分红白葡萄酒

用葡萄酒的化学成分（酸度、糖分、酒精含量等）作为特征


对新葡萄酒，找到k个成分最接近的已知葡萄酒，按多数决定红/白

### 算法特点：懒惰学习

不需要训练阶段

预测时需要计算全部距离

需要特征标准化消除量纲影响



### 异常检测 (Anomaly Detection)

KNN也可用于无监督异常检测

离所有邻居都很远的点→潜在异常

### 应用场景

信用卡欺诈检测·设备故障预警·医疗诊断



## | 第7章 · 局限性 + 小结

### 局限性

#### k值敏感

k值的选择直接影响分类效果

#### 特征缩放

需标准化特征消除量纲影响

#### 计算成本高

大数据集需计算全部距离，耗时

#### 维度灾难

高维空间距离度量失去意义

### 第7章 小结

- ✓ KNN基于"物以类聚"的思想，简单直观
- ✓ 懒惰学习：无需训练但预测成本高
- ✓ KNN可同时用于分类和异常检测
- ✓ 应用：红白葡萄酒分类、欺诈检测、故障预警

# 支持向量机



## 核心知识点

- SVM通过找到最大间隔的分界线（超平面）来提高泛化能力
- 支持向量是离分界线最近的那些数据点，它们唯一决定分界线的位置
- 核技巧将数据映射到高维空间，使线性不可分问题转化为线性可分
- 关键参数：C（惩罚系数）控制误差容忍度，gamma控制核函数形状
- 示例：用患者指标预测心脏病风险

## 8.1 SVM原理 + 核技巧 + 示例

### 最大间隔分类器

线性可分 → 直接找最大间隔分界线

间隔越大 → 泛化能力越强

支持向量 = 距分界线最近的点

只有支持向量决定分界线位置

### 核技巧 (Kernel Trick)

线性不可分 → 用核函数映射到高维空间

常用核函数: RBF (高斯核) / 多项式核

核方法不需显式计算高维坐标

### 关键参数

#### C (惩罚系数)

C越大 → 对错误分类惩罚越重 → 边界更复杂


C越小 → 允许更多错误 → 边界更平滑

#### gamma (核参数)


控制单个样本的影响力半径

gamma过大 → 过拟合 (只关注近邻)

gamma过小 → 欠拟合 (全局线性)



(a) 主成分分析



(b) 独立成分分析

$$\text{支持度} \{ \text{🍏} \} = \frac{4}{8}$$

### 示例: 预测心脏病

用年龄·血压·胆固醇·心率

SVM找出最大间隔分界线

#### 局限性

参数调优需要经验

大规模数据训练时间长

模型可解释性较差

### 第8章 核心要点回顾

---

- ✓ SVM寻找最大间隔分界线，最大化泛化能力
  - ✓ 支持向量唯一决定分界线，其他点不影响
  - ✓ 核技巧解决线性不可分问题
  - ✓ C参数控制分类容错度，gamma控制核函数影响半径
- 

### 原书示例：医学诊断

年轻医生可能因经验不足而误诊，但数据科学可以利用大量病历数据帮助医生做出更准确的诊断。SVM在此场景中找到最佳诊断分界。

---

### 局限性

- 对参数（C、gamma）敏感，调参需要经验
- 大规模数据集上训练时间长
- 模型可解释性比决策树差

# 决策树



## 核心知识点

- 树结构：根节点→内部节点（特征测试）→叶节点（预测结果）
- 分裂指标：信息增益（ID3）、增益率（C4.5）、基尼系数（CART）
- 剪枝防止过拟合：预剪枝（提前停止）/ 后剪枝（生成后再修剪）
- 优点：可解释性强（白箱）、无需特征缩放；缺点：易过拟合、不稳定
- 示例：预测泰坦尼克号幸存者

## 9.1 分裂指标 + 示例：泰坦尼克号

### 三种分裂指标

#### 信息增益 (ID3算法)

基于熵的减少量，熵越低→纯度越高

#### 增益率 (C4.5算法)

对信息增益归一化，减少对多值特征的偏好

#### 基尼系数 (CART算法)

衡量节点不纯度，值越小→节点纯度越高

目标：让子节点的纯度最大化

### 剪枝处理

#### 预剪枝



在树生成过程中提前停止分裂

设置最大深度、最小样本数等阈值

#### 后剪枝

先生成完整的树再修剪

剪掉对泛化能力贡献不大的分支



### 示例：泰坦尼克号

用性别·年龄·船舱等级·票价

决策树预测乘客是否幸存

#### 局限性

易过拟合，需剪枝

对数据微小变化敏感（不稳定）

偏向多值特征

## 第9章 · 小结 + 第10章 随机森林

### 第9章 小结

- ✓ 决策树是可解释性最强的模型之一
- ✓ 分裂指标：信息增益/增益率/基尼系数
- ✓ 需要剪枝防止过拟合
- ✓ 无需特征缩放，可处理混合类型数据

### 随机森林优点

- 👍 比单棵树准确度高得多
- 👍 对缺失值和异常值稳健
- 👍 能输出特征重要性排序
- 👍 无需过多调参即可获良好性能

### 第10章 随机森林概述

核心思想：集体智慧

多个决策树集成 → 性能远超单棵树

#### Bagging (自助聚集法)

有放回抽样 + 并行训练多棵树

投票/平均 → 降低方差，减少过拟合

双重随机性：数据随机 + 特征随机

### 局限性

- 👎 可解释性不如单棵决策树
- 👎 模型较大占用更多内存
- 👎 回归任务不能外推预测
- 👎 对高稀疏类别特征有偏差

## 10.1 Bagging + 示例：预测犯罪行为

### Bagging (自助聚集法)

#### Step 1: 有放回抽样

从原始数据集中抽取多个子集  
每个子集大小与原数据集相同

#### Step 2: 并行训练

用每个子集训练一棵决策树  
每棵树独立生长，互不影响

#### Step 3: 投票/平均

分类→多数投票；回归→取平均  
随机森林额外随机选择特征子集

### 示例：预测犯罪行为

用社区的经济状况、警务覆盖、人口统计  
等指标构建随机森林模型

预测特定区域的犯罪率


可同时处理数值和分类特征

能评估哪些因素对犯罪率影响最大

#### 特征重要性

输出每个特征对预测的贡献度

帮助理解影响因素



### 第10章 小结

- ✓ 随机森林通过集成多棵树大幅提升性能
- ✓ 双重随机性降低树之间的相关性
- ✓ 是目前最常用的机器学习算法之一



# 神经网络

**核心思想：**模拟人脑神经元，通过多层连接的感知器学习数据中的复杂模式

深度学习的基础：层数越多→学习能力越强→但也越容易过拟合、越难训练

## 神经网络结构



## 训练过程


### 前向传播

输入→隐藏层逐层变换→输出→计算损失

### 反向传播

从输出层向输入层反向传播误差→更新权重

激活函数：Sigmoid / Tanh / ReLU → 引入非线性



## 示例：识别手写数字 + 局限性

像素值→多层网络学习映射关系→识别数字

**局限性：**需大量数据计算资源·黑箱可解释性差·超参数众多

# A/B测试与多臂老虎机

## A/B测试

将用户随机分为实验组和对照组  
展示不同版本，比较效果差异  
用统计检验判断差异是否显著

### 局限性

50%用户始终接受较差方案  
需预先确定样本量  
无法动态适应变化


## 多臂老虎机 (epsilon递减)

在探索 (Exploration) 与利用 (Exploitation)  
之间动态平衡

以epsilon概率随机探索不同选项  
以 $(1-\epsilon)$ 概率选择当前最优

epsilon随时间递减→减少探索增加利用

vs A/B测试：无需预确定样本量  
更多用户分配到更好的方案



## 第12章 小结

- ✓ A/B测试是方案验证的标准方法
- ✓ 多臂老虎机通过探索-利用平衡实现动态优化
- ✓ epsilon递减策略：先多探索后多利用，适合在线学习

# 全书总结

《白话机器学习算法》全书12章核心回顾

## 无监督学习 (Ch2-Ch5)

- k均值聚类——发现数据中的自然分组
- PCA——高维数据降维与可视化
- 关联规则——发现共现模式
- 社会网络分析——图结构与关系挖掘

共同特点：数据无标签，由算法自行发现结构

## 监督学习 (Ch6-Ch11)

- 回归分析——预测连续数值
- KNN——物以类聚的分类方法
- SVM——最大间隔分类器
- 决策树——可解释的树形分类器
- 随机森林——集成多棵树提升性能
- 神经网络——深度学习的基础

## 强化学习 (Ch12)

A/B测试与多臂老虎机——通过反馈不断改进的动态优化方法

## 全书基础 (Ch1)

数据准备 → 算法选择 → 参数调优 → 模型评价——贯穿全书的方法论框架

"不依赖个人判断，利用多源信息做出更好的决策"