


第四讲 聚类算法

课后作业 · 笔记整理

K-means聚类 · 层次聚类 · 距离度量

学生：张椅达 | 学号：202321054055

欧氏距离 $d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$



(簇) 标号创建对象的标记。然而，只能从数据导出这些标号。相比之下，分类是监督分类 (Supervised Classification)，即使用由类标号已知的对象开发的模型，对新的、无标记的对象赋予类标号。为此，有时称聚类分析为非监督分类 (Unsupervised Classification)。

此外，尽管术语分割 (Segmentation) 和划分 (Partitioning) 有时也用作聚类的同义词，但是这些术语通常用来表示传统的聚类分析之外的方法。例如，术语划分通常用在与将图分成子图相关的技术，与聚类并无太大联系。分割通常指使用简单的技术将数据分组；例如，图像可以根据像素亮度或颜色分割，人可以根据他们的收入分组。尽管如此，图划分、图像分割和市场分割的许多工作都与聚类分析有关。

9.1.2 类的度量方法

既然要研究聚类，我们就有必要了解不同类的度量方法。纵然类的形式各有不同，但总的来说，常用的类的度量方法有两种，即距离和相似系数。距离用来度量样品之间的相似性，相似系数用来度量变量之间的相似性。

(1) 距离

设 $X_1, X_2, \dots, X_n$ 为取自 p 元总体的样本，记第 i 个样品 $X_i = (x_{i1}, x_{i2}, \dots, x_{ip}) (i = 1, 2, \dots, n)$ 。

聚类分析中常用的距离有以下几种：

① 闵可夫斯基 (Minkowski) 距离

第 i 个样品 X_i 和第 j 个样品 X_j 之间的闵可夫斯基距离 (也称“明氏距离”) 定义为：

$$d_{ij}(q) = \left[\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right]^{1/q}, \quad i = 1, 2, \dots, n; j = 1, 2, \dots, n$$

余弦距离

$\cos AB = \cos \theta = \frac{a \cdot b}{|a||b|} = \frac{x_1x_2 + y_1y_2}{\sqrt{x_1^2 + y_1^2} \sqrt{x_2^2 + y_2^2}}$

$\theta = 0^\circ$ - 完全相同
 $0^\circ < \theta < 90^\circ$ - 具有相似性
 $\theta = 90^\circ$ - 独立 (不相关)
 $90^\circ < \theta < 180^\circ$ - 相斥
 $\theta = 180^\circ$ - 完全相反

在自然科学和社会科学中，存在着大量的聚类问题，其实聚类是一个人们日常生活的常见行为，所谓“物以类聚，人以群分”，其核心思想也是聚类。人们总是不断地改进下意识中的聚类模式来学习如何区分各个事物和人。通过聚类，人们能意识到密集和稀疏的区域，发现全局的分布模式，以及数据属性之间有趣的相互关系。

聚类起源于分类学，在古老的分类学中，人们主要依靠经验和专业知识来实现分类，很少利用数学工具进行定量的分类。随着人类科学技术的发展，对分类的要求越来越高，以致有时仅凭经验和专业知识难以确切地进行分类，于是人们逐渐地把数学工具引用到了分类学中，形成了数值分类学，之后又将多元分析的技术引入到数值分类学形成了聚类。在实践中，聚类往往为分类服务，即先通过聚类来判断事物的合适类别，然后再利用分类技术对新的样本进行分类。

聚类已经广泛地应用在许多应用中，包括模式识别、数据分析、图像处理以及市场研究。作为一个数据挖掘的功能，聚类能作为独立的工具来获得数据分布的情况，观察每个簇的特点，集中对特定的某些簇做进一步的分析，此外，聚类分析还可以作为其他算法的预处理步骤，简化计算量，提高分析效率。本章将介绍聚类的常用方法和典型的应用案例。

9.1 聚类方法概要

9.1.1 聚类的概念

将物理或抽象对象的集合分成由类似的对象组成的多个类或簇（Cluster）的过程被称为聚类（Clustering）。由聚类所生成的簇是一组数据对象的集合，这些对象与同一个簇中的对象

层次一：物以类聚，人以群分（感性）

层次二：同一个簇中的对象相似度高，与其他簇中的对象相似度较低（逻辑）

层次三：同一个组中的记录越相似，而不同组

中的记录越远越好（量化）

| 簇的概念 (Jp187-188)

聚类：将物理或抽象对象的集合分成由类似的对象组成的多个类或簇的过程。

对聚类理解的三个层次

第一层

物以类聚，人以群分

感官层面：直观感受

第二层

同簇相似度高

异簇相似度低

逻辑层面：概念清晰

第三层

组内点越近越好

组间点越远越好

量化层面：可计算可优化

簇的形状

簇的形象表现在空间分布上不是确定的，呈各种不同的形状（球形、条形、环形等）

不同形状的簇需要用不同的聚类算法来处理。降维工具（PCA、t-SNE）可用于可视化高维数据中的簇。

| 类的度量方法 (Jp189-190)

欧氏距离

衡量两点之间的直线距离

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

二维平面上点a(x₁, y₁)与b(x₂, y₂)间的欧氏距离

特点

直观、计算简单、最常用的距离度量
对特征量纲敏感 → 需先做标准化

余弦相似度

衡量两个向量方向上的差异

$$\cos(\theta) = (AB) / (|A| |B|)$$

向量A(x₁, y₁)与向量B(x₂, y₂)的夹角余弦

特点

cosθ越接近1 → 方向越相似
不受向量长度的影响，常用于文本分析

距离度量的选择

K-means默认使用欧氏距离，但可以通过参数 'distance' 指定其他距离（如余弦距离）：
`kidx = kmeans(data, k, 'distance', 'cosine')`
cosθ的含义：值越大（越接近1） → 向量方向越一致 → 相似度越高

K-means聚类：原理与步骤 (Jp192)

工作原理（考试标准）

1

随机选K个点
每个点代表初始簇中心

2

计算距离并分配
把每个点赋给最近的簇

3

更新聚类中心
重新计算每一簇的平均值

4

迭代直到收敛
点的归属不再变化

MATLAB调用方式

```
Idx = kmeans(X, K) | [Idx, C, sumD, D] = kmeans(X, K, 'distance', 'cosine')
```

输出：Idx类目号、C质心坐标、sumD类内距、D点到质心的距离

K-means算法特点（重要）

- ✓ K值事先给定，难以精确估计
- ✓ 结果不稳定：不同初始中心产生不同结果
- ✓ 数据量大时计算时间长，但简洁有效仍是首选

- ✗ 对离散点和初始K值敏感
- ✗ 无法做到将一个点分到不同类别（无交叉）

| 层次聚类 (Jp198)

层次聚类通过将数据组织为若干组并形成一个相应的树（树状图）来进行聚类。

根据层次方向不同：凝聚法（自底向上）和 分裂法（自顶向下）

两种聚类思想

凝聚法 (Agglomerative)

自底向上：每个点自成一簇 →

合并最近的两簇 →

重复直到达到目标类目数k

最常用的一种HC方式

分裂法 (Divisive)

自顶向下：所有点在一个簇 →

将最不相似的簇分裂 →

重复直到每个点自成簇

计算量大，较少使用

凝聚法算法步骤

输入：目标类目数K，数据样本集合D


① 每个样本视为一个类簇

② 循环：找到分属不同两簇且距离最近的样本点对 → 合并这两个簇 → 直到类簇数=K

簇间距离计算方法：最短距离法·最长距离法·平均距离法·重心法

HC树状图 (Dendrogram) 解读 (重点)

树状图 (dendrogram)



树状图怎么看?

- ① 横轴: 数据点 (30个)
- ② 纵轴: 距离/相似度
- ③ 垂直线: 数据点或合并后的簇
- ④ 水平线: 将两个簇合并在一起

如何确定类别数?

画一条横线从上往下平移
与多少条垂直线相交→分几类

例子

红线在位置A (分3类): 与3条垂直线相交 → 3个簇

红线在位置B (分5类): 与5条垂直线相交 → 5个簇

注: dendrogram函数默认底部画30个节点, 使树状图更清晰

K-means vs 层次聚类 对比 + 读书笔记

算法对比

对比维度	K-means	层次聚类
聚类方式	划分聚类	凝聚/分裂
K值	需要预先指定	通过树状图确定
稳定性	结果不稳定	结果稳定
计算复杂度	$O(n)$ 较大规模	$O(n^2)$ 小数据集
簇形状	球形	任意形状
可视化	散点图	树状图（特色）

《白话机器学习》第2章 K-means 读书笔记

- ✓ 核心：找出顾客群，将数据划分为k个群组
- ✓ 步骤：确定k值→选质心→分配→更新→迭代
- ✓ 确定k值：肘部法则（SSE拐点）

- ✓ HC小而巧，展示数据层次结构
- ✓ dendrogram画树状图，默认底部30节点
- ✓ HC计算复杂度高，适用于小数据集

第四次作业总结

聚类算法 · 课后作业六项任务完成情况

任务1：整理簇的概念

聚类三层次：感官→逻辑→量化
簇的形状多样，不同形状适用不同算法

任务2：距离度量方法

欧氏距离：直线距离·最常用·需标准化
余弦相似度：方向差异·文本分析常用

任务3：K-means原理步骤

选K点→分配→更新中心→迭代收敛
特点：简洁有效·K值难定·结果不稳定

任务4：HC算法过程

凝聚法：自底向上合并最近的两簇
树状图展示层次结构·适合小数据集

任务5：树状图解读

横轴数据点·纵轴距离·横线截断定类数
从上往下平移横线→与几条垂直相交→几类

任务6：读书笔记

《白话机器学习》第2章 K-means
肘部法则确定k值·影迷聚类示例

聚类本质：无监督学习 — 发现数据中隐藏的群组结构