

机器学习

简单线性回归

作业解答与核心概念

Topics: 主题: 列向量 | 模型系数 | 决定系数 R^2 评估 | 训练集 / 测试集划分比例

作业总览

问题1

列向量要求

为什么特征 X 必须是二维数组（样本数 $\times 1$ ），而非一维数组。使用行向量会出现什么问题。

问题3

R^2 指标评估

理解 R^2 作为回归模型拟合优度的评价指标。

问题5（扩展）

采用“最小二乘法”实现该模型

问题2

模型方程与系数

提取截距 b_0 和斜率 b_1 ，写出回归方程 $y = b_0 + b_1 \cdot x$ 。

问题4

训练 / 测试集比例的影响

调整数据集划分比例，如何影响训练集与测试集的 R^2 值。

课程回顾：简单线性回归

1

Step 1: 数据预处理

```
X = dataset.iloc[:,0:1].values  
Y = dataset.iloc[:,1].values
```

2

Step 2: 模型训练

```
regressor = LinearRegression()  
regressor.fit(X_train, Y_train)
```

3


Step 3: 模型预测

```
Y_pred = regressor.predict(X_test)
```

4

Step 4: 结果可视化

```
plt.scatter(X_test, Y_test)  
plt.plot(X_test, Y_pred)
```



Q1 为什么 X 必须是列向量?

核心问题

Python 机器学习库 sklearn 的线性回归 fit () 方法, 要求特征 X 为二维数组, 格式为 (样本数量, 特征数量)。
一维数组格式为 (25,), 仅单维度, sklearn 无法识别为特征矩阵, 会直接报错。

正确代码

```
X = dataset.iloc[:, 0:1].values # shape (25,1)
```

错误代码

```
X = dataset.iloc[:, 0].values # shape (25,) -  
Error!
```

核心规则: 特征 X 必须为 (样本数, 特征数) 格式, 始终使用二维矩阵!

Q1: Why X Must Be a Column Vector

Column Vector
(25x1 Matrix $\begin{bmatrix} \end{bmatrix}$)

Row Vector
(1D Array $\begin{bmatrix} \end{bmatrix}$)

Hours
2
5
3
8
3
...

h1	h2	h3	h4	h5	...
2	5	3	8	3	...

Q2 输出训练后的模型方程

$$y = b_0 + b_1 \cdot x$$

$$y = -1.54 + 10.46 \cdot x$$

斜率 (b1)

10.4611

```
b1 = regressor.coef_[0]
```

学习时长每增加 1 小时，预测分数提升约 10.5 分。

截距 (b0)

-1.5370

```
b0 = regressor.intercept_
```

学习时长为 0 时的预测分数（负值为模型外推结果，无实际意义）。

训练集 R^2

0.9638

```
regressor.score(X_train, Y_train)
```

仅学习时长这一个特征，就能解释 96.4% 的分数波动。

Q3 用 R^2 评估模型性能

R^2 定义

决定系数 (R^2) 用于衡量回归拟合线与数据的匹配程度, 取值范围 0~1; 数值越接近 1, 模型对标签 Y 的波动解释能力越强。

```
#  $R^2$  on training set  
R2_train = regressor.score(X_train, Y_train)  
#  $R^2$  on test set  
R2_test = regressor.score(X_test, Y_test)
```


R^2 计算训练集: **0.9638**

96.4% variance explained

R^2 计算测试集: **0.8421**

84.2% variance explained

Train/Test Split Results (80/20)




Q4 训练 / 测试集比例对 R^2 的影响

表格对比

测试集比例	训练集样本量	R^2 训练集	R^2 测试集
10% (2 个样本)	23 pts	0.9523	0.6041
20% (5 个样本)	20 pts	0.9638	0.8421
30% (7 个样本)	17 pts	0.9682	0.8934
40% (10 个样本)	15 pts	0.9705	0.9130
50% (12 个样本)	12 pts	0.9723	0.9153

Key Insights

- 测试集占比越大 $\rightarrow$ 训练集 R^2 越低 (模型学习的数据量减少)
- 测试集占比过小 (10%) $\rightarrow$ 测试集 R^2 结果不可靠
- 20%~30% 的测试集划分比例, 为最优区间



文件(F) 编辑(E) 选择(S) 查看(V) 转到(G) 运行(R) 终端(T) 帮助(H)

← → 搜索

更新

2-regress-1.ipynb X

D:\>大三下>数据挖掘与机器学习>数据挖掘-python实战>数据挖掘-python实战>2-regress-1.ipynb>M4 第2步 训练集, 使用简单线性回归模型来训练 X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2, random_state = 0) # random_state =0 每次运行分配可能不一样。=1就是一样的

生成 + 代码 + Markdown 全部运行 清除所有输出 大三 大纲

(25, 1)

生成 + 代码 + Markdown

```
print(type(X))
```

Python

```
<class 'numpy.ndarray'>
```

Python

```
Y = dataset.iloc[:,1].values
```

Python

```
Y
```

Python

```
array([[21, 47, 27, 75, 30, 20, 88, 60, 81, 25, 85, 62, 41, 42, 17, 95, 30,
        24, 67, 69, 30, 54, 35, 76, 86]])
```

第2步 训练集，使用简单线性回归模型来训练

```
from sklearn.model_selection import train_test_split
```

Python

```
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2, random_state = 0) # random_state =0 每次运行分配可能不一样。=1就是一样的
```

Python

```
from sklearn.linear_model import LinearRegression # 从liner_model库中, 调出LinearRegression类
```

Python

```
regressor = LinearRegression() # 创建regressor对象。我们称为生模型
```

Python

```
regressor
```

Python

```
LinearRegression
```

Python

```
# 不划分测试集和训练集
```

Python

```
regressor = regressor.fit(X,Y)
```

Python

Spaces: 4 (1) 单元路 14/47

Q5 采用“最小二乘法”实现该模型



The image displays two side-by-side screenshots of a Jupyter Notebook titled "3_Multiple_Linear_Regression.ipynb". The notebook is open to the "最小二乘法实现代码.py" file.

Left Screenshot:

- Code:** The code imports pandas, numpy, and matplotlib. It loads the 'studentscores.csv' dataset and splits it into training and testing sets using `train_test_split`. It then calculates the mean of the training data and the mean of the testing data. The least squares method is implemented using the formula $b_1 = \frac{\sum[(x_i - \bar{x})(y_i - \bar{y})]}{\sum[(x_i - \bar{x})^2]}$ and $b_0 = \bar{y} - b_1 \bar{x}$. The model is evaluated using `R^2` score.
- Output:** The output shows the calculated values for b_0 and b_1 , and the R^2 score for the training set.

Right Screenshot:

- Code:** The code continues with the evaluation of the model. It calculates the R^2 score for the training set and the testing set. It also visualizes the data points and the fitted line using `plt.scatter` and `plt.plot`.
- Output:** The output shows the calculated values for R^2 score for the training set and the testing set, and the visualization of the data points and the fitted line.



对比项	左图（训练集）	右图（测试集）
数据来源	80% 的原始数据	20% 的原始数据
是否参与训练	☒ 是	☒ 否
散点类型	只有真实值（红）	真实值（红）+ 预测值（黑）
目的	检查拟合效果	检查泛化能力