

机器学习100天 · 第3天

多元线性回归

50_Startups数据集 · 3个自变量 · 1个分类变量

作业完成内容

作业1：观察数据集特征 · 作业2：OneHot编码过程

作业3： R^2 评估结果 · 作业4：回归系数与截距分析

作业5：分类变量对回归的影响 · 作业6：Label化vs OneHot

学生：张椅达 | 学号：202321054055

作业1：观察数据集特征

数据集有几个特征？几列属性？分类变量是什么？数值变量之间与利润的关系如何？




```
import pandas as pd, numpy as np
dataset = pd.read_csv('50_Startups.csv')
print(dataset.head(10))

R&D Spend Admin Marketing Spend State Profit
0 165349.2 136897.8 471784.1 New York 192261.8
1 162597.7 151377.6 443898.5 Calif. 191792.1
2 153441.5 101145.6 407934.5 Florida 191050.4
...

print(dataset.shape) # (50, 5)
print(dataset.describe())
☑50行5列：3数值+1分类(State)+1目标(Profit)
```

分析结论

- ① 数据集共50条记录，5个字段
- ② 分类变量：State（3类：NY/CA/FL）
- ③ R&D与Profit正相关最强（红色）
- ④ Admin/ Marketing与Profit相关性弱
- ⑤ 需OneHot编码State列



作业2：OneHot编码（分类变量数字化）

💡如何把分类变量State转化为OneHot？过程是什么？为什么不能直接Label化？

```
# Step 1: LabelEncoder - 文字->数字
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
X[:, 3] = le.fit_transform(X[:, 3])
# Calif.=0, Florida=1, New York=2

# Step 2: OneHotEncoder - 1列->3列
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import ColumnTransformer
ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [3])], remainder='passthrough')
X = np.array(ct.fit_transform(X))

# Step 3: 避免虚拟变量陷阱（删一列）
X = X[:, 3:6] # 保留后3列数值特征
```

OneHot编码前后对比

编码后X形状：(50, 6) → 3列OneHot+3列数值

前5行（OneHot部分|数值部分）：

```
[0,0,1 | 165349.2, 136897.8, 471784.1] NY
[1,0,0 | 162597.7, 151377.6, 443898.5] CA
[0,1,0 | 153441.5, 101145.6, 407934.5] FL
[0,0,1 | 144372.4, 118671.9, 383199.6] NY
[0,1,0 | 142107.3, 91391.77, 366168.4] FL
```

⚠能否直接Label(0,1,2)计算？

不能！Label(0,1,2)会赋予类别大小关系

→ 模型认为2比1大、1比0大

→ OneHot编码确保类别无大小关系

作业3：训练模型 + 预测结果 + R^2 评估


🔮如何训练多元线性回归模型？如何评估结果？ R^2 的含义是什么？

```
from sklearn.model_selection import train_test_split
X_train, X_test, Y_train, Y_test =
    train_test_split(X, Y, test_size=0.2, random_state=0)

# 训练：40条训练 | 10条测试
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, Y_train)

# 预测测试集
y_pred = regressor.predict(X_test)

#  $R^2$ 评估
R2 = regressor.score(X, Y)
print(f'R² = {R2:.6f}')
```




测试集实际值 vs 预测值：

样本	实际Y	预测Y_pred	差值
1	103282.4	103901.9	+619.5
2	144259.4	132763.1	-11496.3
3	146122.0	133567.9	-12554.1
4	77798.8	72911.8	-4887.0
5	191050.4	179627.9	-11422.5
...			

$R^2 = 0.9491$

$R^2 = 0.9491$ ，说明自变量可以解释

94.91%的因变量变异 → 拟合效果非常好




作业4：回归系数与截距分析

🔗 回归系数(权重)和截距是多少？数学公式是什么？如何解读系数含义？

```
# 获取系数 (权重)
bi = regressor.coef_
print(bi)
# [0.77884104, 0.0293919, 0.03471025]

# 获取截距
b0 = regressor.intercept_
print(b0)
# 42989.01
```




最终回归公式

$$\begin{aligned} \text{Profit} = & 0.779 \times \text{R\&D} \\ & + 0.029 \times \text{Admin} \\ & + 0.035 \times \text{Marketing} \\ & + 42989.01 \end{aligned}$$

R&D每增加1元 → 利润增加0.779元 (最大影响)

Admin每增加1元 → 利润增加0.029元 (影响最小)



作业5&6：分类变量影响 + Label化vs OneHot讨论

作业5：分类变量对回归的影响

- ① State是3类分类变量(CA/FL/NY)
- ② OneHot展开为3列二进制特征
- ③ 删除1列避免共线性后，剩下3个连续特征
- ④ State列被移除，不参与回归方程
- ⑤ 影响：OneHot增维但不改变数值特征结构
- ⑥ 对于不同州的分析可以分别拟合模型

作业6：Label化(0,1,2)是否合理？

✗不合理！

原因：LabelEncoder会赋予类别大小关系

假设 CA→0, FL→1, NY→2

模型中FL的效应是CA的2倍，NY是CA的3倍

State(0,1,2)之间没有大小关系！

正确做法：OneHot编码（不假定大小关系）

或OrdinalEncoder（有序分类变量时可用）

作业总结与知识收获

作业1

50条5列数据，3数值+1分类+1目标，R&D与利润正相关最强

作业2

LabelEncoder+OneHotEncoder+删列，避免虚拟变量陷阱

作业3

$R^2=0.9491$ （自变量解释94.91%变异），模型效果很好

作业4

公式：Profit=0.779×R&D+0.029×Admin+0.035×Marketing+42989

作业5

OneHot编码后分类变量参与或不参与回归均可

作业6

✗ 直接Label不合理，赋予类别虚假的大小关系

特征重要性分析与模型诊断

模型诊断一：特征贡献度分析

回归系数的绝对值反映特征对目标的影响大小：

$|w_1| = 0.779$ (R&D投入)


$|w_3| = 0.035$ (Marketing投入)

$|w_2| = 0.029$ (行政支出)

结论：R&D对利润的影响是Admin的

26.8倍，是Marketing的 **22.4倍**

→ 创业公司应将资源优先投入研发



模型诊断二：残差分析

残差 = 实际值 - 预测值


最大正残差：+10158 (预测偏低)

最大负残差：-14115 (预测偏高)

残差均值 ≈ 0 ✓ (无偏估计)

线性回归的四大假设检验：

- ① 线性关系 ✓ (散点图呈线性)
- ② 残差独立 (Durbin-Watson检验)
- ③ 残差同方差 ✓ (残差图无明显喇叭形)
- ④ 残差正态 (Q-Q图检验)



完整Python代码

```
import pandas as pd, numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
from sklearn.compose import ColumnTransformer

# 1. 加载数据
dataset = pd.read_csv('50_Startups.csv')
X = dataset.iloc[:, 0:4].values; Y = dataset.iloc[:, 4].values

# 2. OneHot编码
le = LabelEncoder(); X[:,3] = le.fit_transform(X[:,3])
ct = ColumnTransformer([('encoder', OneHotEncoder(), [3])], remainder='passthrough')
X = np.array(ct.fit_transform(X))[:, 3:6]

# 3. 训练测试划分
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, random_state=0)

# 4. 训练 + 预测 + 评估
regressor = LinearRegression(); regressor.fit(X_train, Y_train)
y_pred = regressor.predict(X_test)
R2 = regressor.score(X, Y)
coeff = regressor.coef_; intercept = regressor.intercept_

# 5. 输出
print(f'R2={R2:.4f}, coeff={coeff}, intercept={intercept:.2f}')
```

💡 学习反思

本次作业的核心收获：

1 ☐ 数据预处理是基础

缺失值、分类变量编码、
特征缩放直接影响模型效果

2 ☐ OneHot编码必要性

分类变量不能直接用Label代替
防止模型学到错误的大小关系

3 ☐ R^2 不是万能的

R^2 高不代表模型一定好
需结合残差分析诊断模型

4 ☐ 业务解释同样重要

回归系数的经济含义
R&D的26.8倍影响→决策建议

多元线性回归的完整流程

EDA → 编码 → 划分 → 训练 →
评估 → 诊断 → 解释