

机器学习 · 聚类分析

K-means + 层次聚类 Python

Iris鸢尾花数据集 · 4个特征 · 3类花 · 150条记录

作业完成内容

作业1: 用花萼特征(列0,1)聚类 · 作业2: 用全部4列特征聚类
作业3: K=2实验 · 作业4: 肘部法则 + 聚类中心可视化 + HC+Dendrogram



学生: 张椅达 | 学号: 202321054055

作业1+2: K-means k=3 — 花瓣vs花萼 + 4D特征

```
from sklearn.cluster import KMeans
from sklearn.datasets import load_iris
iris = load_iris()
X = iris.data # (150, 4)

# 花瓣特征
X_petal = X[:, 2:4] # petal length, width

# K-means k=3
kmeans = KMeans(n_clusters=3, n_init=10, random_state=42)
labels = kmeans.fit_predict(X_petal)
```




📊花瓣聚类结果 (左图)

- 聚类中心: C0[5.60,2.04] C1[1.46,0.25] C2[4.27,1.34]
- 三类划分清晰, 基本对应setosa/versicolor/virginica
- setosa(小花)完全分开, versicolor和virginica有少量重叠

📊花萼聚类结果 (右图)


- 三类重叠严重, 边界模糊
- 花萼特征对鸢尾花区分能力弱→需要选择合适特征

作业2: 4维特征聚类 → PCA投影可视化




4D数据通过PCA降到2D后, 三类聚类效果较好 (边界比花瓣聚类略模糊)


作业3+4: K=2实验 + 肘部法则 + 聚类中心可视化



K-means K=2 (花瓣)



肘部法则 (Elbow)




HC层次聚类 K=3

实验分析

- K=2 (左图) : setosa独为一类, versicolor+virginica合并 → 2类也合理但信息损失大
- 肘部法则 (中图) : K=3处出现明显拐点 → K=3为最优值, 与真实分类数一致
- HC层次聚类 (右图) : Ward距离, 与K-means结果基本一致, 三类划分清晰

作业4（续）：HC树状图 + K-means vs HC对比 + 总结



树状图解读

- 横轴：样本点（30个节点）
- 纵轴：距离（Ward距离）
- 红色虚线：切在 $d=3$ 位置
→ 与3条垂直线相交=3类
- 橙色虚线：切在 $d=5$ 位置
→ 与2条垂直线相交=2类

HC vs K-means

相同点： $k=3$ 时聚类结果基本一致
不同点：HC展示层次结构·需dendrogram
K-means计算快·适合大数据·有聚类中心

作业总结与知识收获

作业1 花萼聚类效果差→特征选择很重要

作业2 4D+PCA投影聚类→高维也可聚类

作业3 K=2简单但信息损失

作业4 肘部法则确定K=3最优

深入理解：花瓣特征>花萼特征，特征选取直接影响聚类质量；肘部法则是K-means确定K值的重要方法；HC树状图可直观展示层次结构

K-means深入：初始化方式 + n_init的影响 + 算法收敛

初始化方式对比

K-means对初始质心选择敏感

随机初始化 (random)

随机选取k个样本作为初始质心

缺点：不同运行结果可能不同

K-means++ (默认推荐)

第一个质心随机，后续离已有质心越远

越可能被选为下一个质心

→ 结果更稳定，收敛更快

n_init参数与算法收敛

```
KMeans(n_clusters=3, n_init=10, random_state=42)
```

n_init=10：用10组不同的初始质心

分别运行K-means

最终选择inertia(SSE)最小的结果

本次实验中的inertia：

K=2: Inertia=152.35

K=3: Inertia=78.85 ☒ 最优

K=4: Inertia=58.52

Inertia随着K增大而减小，但K=3后下降趋缓

聚类中心可视化（花瓣特征）

Cluster 0: center=[5.60, 2.04], size=48 → Iris-virginica (大花)

Cluster 1: center=[1.46, 0.25], size=50 → Iris-setosa (小花)

Cluster 2: center=[4.27, 1.34], size=52 → Iris-versicolor (中花)

聚类中心反映了各类花的典型特征：setosa花瓣最小(1.46cm×0.25cm)，virginica最大(5.60cm×2.04cm)

层次聚类深入：连接方式对比 + 完整代码

层次聚类连接方式对比

```
from scipy.cluster.hierarchy import dendrogram, linkage
from sklearn.cluster import AgglomerativeClustering
```

Ward连接

合并时使SSE增量最小（本次实验使用）

→ 产生大小相近的簇，适合球形数据

最大距离法 (complete)

合并两簇中最远点之间的距离

平均距离法 (average)

合并两簇中所有点之间的平均距离

完整聚类代码

```
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.datasets import load_iris
from scipy.cluster.hierarchy import dendrogram, linkage
import matplotlib.pyplot as plt

iris = load_iris(); X = iris.data[:,2:4]
kmeans = KMeans(n_clusters=3, n_init=10, random_state=42).fit(X)
hc = AgglomerativeClustering(n_clusters=3, linkage='ward').fit(X)

linked = linkage(X, method='ward')
dendrogram(linked); plt.show() # 绘制树状图
```

树状图详细解读

纵轴（距离）：数值越大→簇越不相似

水平线：合并两个簇的位置

横切判断类数：

红色虚线(d=3)→3条垂直线→3类

橙色虚线(d=5)→2条垂直线→2类

HC算法特点：

- 可视化层次结构（树状图）
- 不需预先指定K（从树状图定）

● 计算复杂度O(n³)，适合小数据

K-means vs HC + 评估指标 + 特征选择讨论

K-means vs 层次聚类对比

K-means

需预指定K值·结果不稳定·球形假设

计算 $O(n)$ ·适合大数据·有聚类中心

层次聚类(HC)

树状图展层次·不需要预知K·稳定

计算 $O(n^3) \sim O(n^2)$ ·适合小数据·无中心

特征选择讨论

为什么花瓣特征优于花萼？

花瓣长/宽在不同品种间差异显著

花萼长/宽在不同品种间有重叠

启发：聚类效果不仅取决于算法

特征选择同样关键！

→ 降维可视化(PCA/t-SNE)有助于发现有效特征

聚类效果评估方法

外部评估（有真实标签时）

- 调整兰德指数(ARI) / 互信息(NMI)

内部评估（无真实标签时）

- 轮廓系数(Silhouette): $[-1, 1]$, 越大越好
- Inertia(SSE): 越小越好（肘部法则用）

💡 重要认知

- 1 ☐ 聚类是无监督学习→真实标签
仅用于评估，不参与训练
- 2 ☐ K-means假设数据是球形分布
非凸形状→DBSCAN等密度聚类
- 3 ☐ HC通过树状图直观展示层次
适合探索性数据分析

作业完成情况

作业1：花萼特征(列0,1)聚类

三类重叠严重→花萼区分能力弱

作业2：全部4列特征聚类

PCA投影后聚类边界较好（优于花萼）

作业3：K=2实验

setosa独为一类，versicolor+virginica合并

🔑核心收获

- 1 ☐ 特征选择决定聚类质量上限
- 2 ☐ 肘部法则+K=3验证了鸢尾花的三类分法
- 3 ☐ K-means与HC结果一致→聚类有效
- 4 ☐ HC的树状图比K-means更直观
- 5 ☐ 聚类是无监督学习的核心方法

作业4：聚类中心+肘部+HC

- 聚类中心可视化☑
- 肘部法则→K=3最优☑
- HC树状图+解读☑

聚类中心：

setosa: [1.46, 0.25] (最小)

versicolor: [4.27, 1.34]

virginica: [5.60, 2.04] (最大)

📊分类 vs 聚类 对比总结

分类（有监督）

数据有标签·已知类别·KNN/SVM/决策树

聚类（无监督）

数据无标签·发现类别·K-means/HC/DBSCAN

两者都是数据挖掘中最基础的"两根柱子"