



第一讲作业

信管2302钟京序
202321054056



一，认识大数据挖掘



一，认识大数据挖掘

- **大数据 (Big Data)**

定义：以多样形式（TB/PB级）存在，具备Volume（体量巨大）、Velocity（速度快）、Variety（多样）、Value（价值密度低）特征的数据集合。技术分支：大数据存储（关系数据库、云存储、分布式存储）与大数据应用（数据管理、统计分析、数据挖掘、并行计算、分布式计算）

- **数据挖掘 (Data Mining)**

定义：从大量、不完全、有噪声的应用数据中，提取隐含、未知且有价值的信息与知识的过程。核心价值：将海量数据转化为商业价值

- 数据挖掘类型：关联、回归、分类、聚类、预测、诊断

- **大数据挖掘要点：**

1. 大数据思维：数据意识、创新思维、开源思维
2. 数据预处理：解决数据质量、集成、清洗等问题
3. 大数据计算：并行计算与分布式计算



➤ 二，数据挖掘的过程及工具 ◀

二，数据挖掘的过程及工具（**DPEMED**）

DPEMED六阶段：

1. 挖掘目标定义（D）：明确业务问题与预期效果，需结合行业知识界定问题范围
2. 数据准备（P）：数据选择、数据质量检查、数据预处理（清洗、集成、变换、归约）
3. 数据探索（E）：初步分析，了解特征、选择变量，为建模提供依据
4. 模型建立（M）：选择适配的模型/算法，训练并调参，使用交叉验证等方法评估
5. 模型评估（E）：从商业价值与技术指标双维度评估（精度、LIFT、ROC等）
6. 模型部署（D）：将验证后的模型应用于业务系统，持续监控并迭代优化



三，数据的准备

三，数据的准备

一、数据的收集

- 数据属性：由数据对象（实体）和属性（特征/字段）构成
- 数据存在形式：结构化数据（数据库）、非结构化数据（文本、图像、视频）、半结构化数据（邮件、HTML）
- 抽样方法：简单随机抽样、系统抽样、整群抽样、分层抽样、多阶段抽样

二、数据质量分析

- 正确性：缺失值、数据错误、度量标准错误、编码不一致
- 有效性：唯一值分析、无效值分析、异常值分析
- 分析方法：描述统计（均值、中位数、众数、标准差等）

三、数据预处理

- 数据清洗：缺失值处理（删除法/插补法）、噪声处理
- 数据集成：多源数据整合，解决冗余与格式冲突
- 数据归约：特征归约（PCA降维）、样本归约
- 数据变换：标准化（0-1/Z-score）、离散化、语义变换



四，数据的探索



四，数据的探索

核心定位：数据探索是连接数据准备与建模的桥梁

- 核心是"发现规律、验证假设、明确方向"
- 衍生变量：由原始变量通过四则运算、组合、变换衍生而来
- 数据的统计：位置统计量（均值、中位数、众数）
- 离散统计量（极差、标准差、方差）
- 分布形态统计量（偏度、峰度）
- 数据可视化：将抽象数据转化为直观图形，快速识别分布与异常
- 数据降维（PCA）：将多个相关变量线性组合为少数互不相关的主成分
- 步骤：标准化→计算相关系数矩阵→求特征值→提取主成分
- 相关系数：筛选高关联变量，为特征选择提供依据



THANKS FOR WATCHING



信管2302钟京序
202321054056