



K-means聚类分析






一、鸢尾花数据可视化观察

鸢尾花特征分布

- 通过数据可视化观察三种鸢尾花的特征分布：
- 绿色：花萼短而宽的鸢尾花
- 蓝色：花萼短而窄的鸢尾花
- 红色：花萼长而窄的鸢尾花
- 不同鸢尾花在花萼长宽、花瓣长宽等特征上
- 表现出明显的聚类趋势，
- 为K-means聚类提供了良好的数据基础。

```
[5]: X = iris.data[:]  
  
[7]: X.shape  
[7]: (150, 4)  
  
[9]: X_2 = iris.data[:,0:2]  
  
[19]: plt.scatter(X_2[:,0],X_2[:,1], c = "red", marker = 'o', label='one flower')  
plt.xlabel('sepal length')  
plt.ylabel('sepal width')  
plt.legend(loc=2)  
plt.show()
```





二、主成分分析 (PCA)

PCA降维与主成分载荷

通过PCA将原始数据降维成两个成分。

PC1（第一主成分）：

与花瓣长度强正相关，与花萼长、花瓣宽中等正相关
主要衡量花朵的整体大小，特别是花瓣长度

PC2（第二主成分）：

与花萼长和宽较强正相关
主要衡量花萼的形状大小

PCA帮助从高维数据中提取关键特征，
为后续聚类提供更有用的低维表示。

```
[27]: X_3 = iris.data[:,:]  
      estimator = KMeans(n_clusters=3)  
      estimator.fit(X_3)
```

```
[27]: KMeans  
      KMeans(n_clusters=3)
```



```
[29]: label_pred = estimator.labels_  
      label_pred
```

```
[29]: array([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,  
          0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,  
          0, 0, 0, 0, 0, 0, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,  
          1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1,  
          1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 2, 2, 2, 1, 2, 2, 2,  
          2, 2, 2, 1, 1, 2, 2, 2, 2, 1, 2, 1, 2, 1, 2, 2, 1, 1, 2, 2, 2, 2,  
          2, 1, 2, 2, 2, 2, 1, 2, 2, 2, 1, 2, 2, 2, 1, 2, 2, 1])
```



三、聚类

聚类结果与三类对比



将鸢尾花数据集分为3类 ($K=3$)，
与实际三种鸢尾花类别对比。

分析关注：

- 聚类是否正确区分不同品种
- 各聚类中心的位置与特征
- 聚类结果的准确性和可解释性


通过PCA可视化：

将聚类结果在PC1-PC2平面展示

直观观察不同类别在降维空间的分布

方法汇总

- 分析输出汇总：
- `kmeans.labels_` → 聚类标签
- `kmeans.cluster_centers_` → 聚类中心
- `kmeans.inertia_` → 评估K值
- 肘部法则：寻找斜率不再急剧变化的转折点
- 确定最佳的聚类数量K
- 聚类中心反映各簇的典型特征，
- 帮助理解不同类别的差异。



实验总结

- 1. 数据可视化：观察三种鸢尾花的特征分布
- 2. PCA降维：将多维特征降至两个主成分
- PC1衡量花朵整体大小，PC2衡量花萼形状
- 3. 聚类：
 - 通过labels_、cluster_centers_、inertia_评估
 - 使用肘部法则确定最优K值
- 4. 结果对比：将聚类结果与真实类别对比



➤

谢谢观看

➤

信管2302钟京序
202321054056