



聚类算法作业

信管2302钟京序
202321054056



1. 整理簇的概念

簇的核心概念与关键特征

- 簇是物理或抽象对象的集合中，由相似度较高的对象组成的子集，
- 是聚类分析的核心单元。
- 关键特征：
- 同一簇内的对象彼此相似，不同簇之间的对象相似度较低。
- 相似度通常通过属性值（如距离）度量。
- 核心判定逻辑：空间上靠拢、组内相似、组间异质
- 形态无固定性：簇的空间分布没有统一形状，
- 二维平面中可呈现圆形、不规则团块、弧形、螺旋形等多样形态。



簇与降维 / 可视化的关联

簇与降维 / 可视化的关联

簇的形态与分布特征，是降维与可视化算法的核心分析对象。

常用降维/可视化算法：PCA、SVD、t-SNE

这些算法的作用：将高维空间中的簇结构映射到二维/三维平面，直观呈现簇的形态、簇间边界、簇的数量与分布。

不同算法适配不同簇形态：

PCA更适合捕捉线性可分的簇结构，

t-SNE更擅长展现非线性、复杂形状（如螺旋形、弧形）的簇分布。

➤ 2. 距离度量的两种基本方法 ◀

欧式距离与余弦距离

欧式距离

$$d_{ij}(2) = \left[\sum_{k=1}^p |x_{ik} - x_{jk}|^2 \right]^{1/2}, \quad i=1,2,\dots,n; j=1,2,\dots,n$$

欧氏距离：衡量两个点在空间中的绝对距离（位置远近）

余弦距离：衡量两个向量方向一致性的指标

不关注向量的绝对长度（模长），只关注方向
 $\cos \theta$ 越高，代表两个对象的特征变化规律越相似

示例：向量 (2, 4) 和 (1, 2)，模长不同，方向一致， $\cos \theta = 1$

向量 (1, 0) 和 (0, 1)，模长相同，方向垂直， $\cos \theta = 0$

余弦距离

$$C_{ij}(1) = \frac{\sum_{k=1}^n x_{ki} x_{kj}}{\left[\left(\sum_{k=1}^n x_{ki}^2 \right) \left(\sum_{k=1}^n x_{kj}^2 \right) \right]^{1/2}}, \quad i=1,2,\dots,p; j=1,2,\dots,p$$

➤ 3. K-means算法的原理和步骤◀

K-means算法步骤

- ① 随机从数据集中选取K个点，每个点初始地代表每个簇的聚类中心
- ② 计算剩余各个样本到聚类中心的距离，将它赋给最近的簇
- ③ 重新计算每一簇的平均值，作为新的聚类中心
- ④ 反复迭代，如果相邻两次调整没有明显变化（点的归属或聚类中心不再改变），说明聚类已收敛




K-means算法完整过程

K-means算法完整过程（图a~图f）

- 1. 初始状态（图a）：输入待聚类的原始数据集
- 2. 初始化（图b）：随机选取K=2个初始聚类中心
- 3. 第一次迭代·簇分配（图c）：按距离最近原则分配样本
- 4. 第一次迭代·中心更新（图d）：计算各簇均值更新中心
- 5. 第二次迭代·簇分配（图e）：修正错分样本
- 6. 第二次迭代·收敛（图f）：中心不再变化，输出结果

- 关键：初始中心位置偏差会导致部分样本错分，
- 经过迭代修正后可正确收敛。





4. 整理HC算法的过程



HC算法（层次聚类）

层次聚类（Hierarchical Clustering）算法过程：

1. 将每个样本看作一个独立的簇
2. 计算所有簇两两之间的距离
3. 合并距离最近的两个簇为一个新簇
4. 重新计算新簇与其他簇之间的距离
5. 重复步骤3-4，直到所有样本合并为一个簇
6. 根据预设的聚类数量，在树状图上画一条水平线截断得到对应的聚类结果



5. HC聚类结果的图




HC聚类结果图解读

图的关键：纵轴是标准距离，画一条水平红线，

红线与多少条竖线相交，就对应分成多少类。

示例：如果聚成5类，就在树状图上画一条水平线，使其恰好与5条竖线相交。

这种方法可以直观地确定最佳的聚类数量。



➤ 6. 《白话机器学习》 K-means 读书笔记 ◀

K-means读书笔记

K-means是经典的基于划分的聚类算法，
核心思想是通过迭代优化使簇内距离最小化。

优点：算法简单、收敛速度快、适合大数据集

缺点：需要预设K值、对初始中心敏感、
只适用于凸形簇、对噪声和异常值敏感

改进方法：多次运行取最优、K-means++优化初始
化、
使用轮廓系数等指标评估聚类效果



THANKS FOR WATCHING



信管2302钟京序
202321054056