



第三次作业

信管2302钟京序
202321054056

➤ CONTENT ◀

01、分类算法基本
逻辑

02、分类算法几个
基本概念

03、KNN算法的思
想与计算步骤


04、第七章，第九
章读书笔记

➤ 分类算法基本逻辑 ◀

基本逻辑

分类是一种重要的数据挖掘技术。分类的目的是根据数据集的特点构造一个分类函数或分类模型（也常常称作分类器），该模型能把未知类别的样本映射到给定的类别中。

分类方法是解决分类问题的方法，是数据挖掘、机器学习和模式识别中一个重要的研究领域。分类算法通过对已知类别训练集的分析，从中发现分类规则，以此预测新数据的类别。分类算法的应用非常广泛，包括银行中风险评估、客户类别分类、文本检索和搜索引擎分类、安全领域中的入侵检测以及软件项目中的应用等。本章将介绍分类的基本概念、常用分类方法的理论及应用实例。



所以分类（Classification）也可以定义为：

对现有的数据进行学习，得到一个目标函数或规则，把每个属性集 x 映射到一个预先定义类标号 y 。

目标函数或规则也称分类模型（Classification Model），分类模型有两个主要作用：一是描述性建模，即作为解释性的工具，用于区分不同类中的对象；二是预测性建模，即用于预测未知记录的类标号。



➤分类算法几个基本概念◀

基本概念主要有分类器，训练集，类标签，测试集，开放集

8.1 分类方法概要

8.1.1 分类的概念

数据挖掘中分类的目的是学会一个分类函数或分类模型（也常常称作分类器），该模型能把数据库中的数据项映射到给定类别中的某一个。

分类可描述如下：输入数据，或称训练集（Training Set），是由一条条数据库记录（Record）组成的。每一条记录包含若干个属性（Attribute），组成一个特征向量。训练集的每条记录还有一个特定的类标签（Class Label）与之对应。该类标签是系统的输入，通常是以往的一些经验数据。一个具体样本的形式可为样本向量： $(v_1, v_2, \dots, v_n; c)$ ，在这里 v_i 表示字段值， c 表示类别。分类的目的是：分析输入数据，通过在训练集中的数据表现出来的特性，为每一个类找到一种准确的描述或者模型。由此生成的类描述用来对未来的测试数据进行分

8.1.2 分类的原理

分类方法是一种根据输入数据集建立分类模型的系统方法，这些方法都是使用一种学习算法（Learning Algorithm）确定分类模型，使该模型能够很好地拟合输入数据中类标号和属性集之间的联系。学习算法得到的模型不仅要很好地拟合输入数据，还要能够正确地预测未知样本的类标号。因此，训练算法的主要目标就是建立具有很好泛化能力的模型，即建立能够准确地预测未知样本类标号的模型。

图 8-1 展示了解决分类问题的一般方法。首先，需要一个训练集，它由类标号已知的记录组成。使用训练集建立分类模型，该模型随后将运用于检验集（Test Set），检验集由类标号未知的记录组成。

通常分类学习所获得的模型可以表示为分类规则形式、决策树形式或数学公式形式。例如，给定一个顾客信用信息数据库，通过学习所获得的分类规则可用于识别顾客是否具有好的信用等级或一般的信用等级。分类规则也可用于对今后未知所属类别的数据进行识别判断，同时也可以帮助用户更好地了解数据库中的内容。




图 8-1 分类原理示意图

构造模型的过程一般分为训练和测试两个阶段。在构造模型之前，要求将数据集随机地分为训练数据集和测试数据集。在训练阶段，使用训练数据集，通过分析由属性描述的数据库元组来构造模型，假定每个元组属于一个预定义的类，由一个称作类标号属性的属性来确定。训练数据集的单个元组也称作训练样本，一个具体样本的形式可为： $(u_1, u_2, \dots, u_n; c)$ ；其中 u_i 表示属性值， c 表示类别。由于提供了每个训练样本的类标号，该阶段也称为有指导的学习，通常，模型用分类规则、判定树或数学公式的形式提供。在测试阶段，使用测试数据集来评估模型的分类准确率，如果认为模型的准确率可以接受，就可以用该模型对其他数据元组进行分类。一般来说，测试阶段的代价远远低于训练阶段。

➤KNN算法的思想与计算步骤◀

8.2 K-近邻

基于数据经验的分类算法

8.2.1 K-近邻原理

K-近邻 (K-Nearest Neighbor, KNN) 算法是一种基于实例的分类方法, 最初由 Cover 和 Hart 于 1968 年提出, 是一种非参数的分类技术。

① K-近邻分类方法通过计算每个训练样例到待分类样品的距离, ② 取和待分类样品距离最近的 K 个训练样例, ③ K 个样品中哪个类别的训练样例占多数, ④ 则待分类元组就属于哪个类别。使用最近邻确定类别的合理性可用下面的谚语来说明: “如果走像鸭子, 叫像鸭子, 看起来还像鸭子, 那么它很可能就是一只鸭子”, 如图 8-3 所示。最近邻分类器把每个样例看作 d 维空间上的一个数据点, 其中 d 是属性个数。给定一个测试样例, 我们可以计算该测试样例




图 8-2 常用的分类方法




图 8-3 KNN 方法原理示意图

与训练集中其他数据点的距离 (邻近度), 给定样例 z 的 K -最近邻是指找出和 z 距离最近的 K 个数据点。

图 8-4 给出了位于圆圈中心的数据点的 1-最近邻、2-最近邻和 3-最近邻。该数据点根据其近邻的类标号进行分类。如果数据点的近邻中含有多个类标号, 则将该数据点指派到其最近邻的多数类。在图 8-4a 中, 数据点的 1-最近邻是一个负例, 因此该点被指派到负类。如果最近邻是三个, 如图 8-4c 所示, 其中包括两个正例和一个负例, 根据多数表决方案, 该点被指派到正类。在最近邻中正例和负例个数相同的情况下 (如图 8-4b 所示), 可随机选择一个类标号来分类该点。




图 8-4 一个实例的 1-最近邻、2-最近邻和 3-最近邻

算法步骤

KNN 算法具体步骤如下:

- 步骤 1: 初始化距离为最大值。
- 步骤 2: 计算未知样本和每个训练样本的距离 $dist$ 。
- 步骤 3: 得到目前 K 个最近邻样本中的最大距离 $maxdist$ 。
- 步骤 4: 如果 $dist$ 小于 $maxdist$, 则将该训练样本作为 K -最近邻样本。
- 步骤 5: 重复步骤 2~步骤 4, 直到未知样本和所有训练样本的距离都算完。
- 步骤 6: 统计 K 个最近邻样本中每个类别出现的次数。
- 步骤 7: 选择出现频率最大的类别作为未知样本的类别

根据 KNN 算法的原理和步骤可以看出, KNN 算法对 K 值的依赖较高, 所以 K 值的选择非常重要。如果 K 太小, 预测目标容易产生变动性; 相反, 如果 K 太大, 最近邻分类器可能会误分类测试样例, 因为最近邻列表中可能包含远离其近邻的数据点 (见图 8-5)。推定 K 值的有益途径是通过有效参数的数目这个概念, 有效参数的数目是和 K 值相关的, 大致等于 n/K , 其中, n 是这个训练数据集中实例的数目。在实践中往往通过若干次实验来确定 K 值, 取分类误差率最小的 K 值。




图 8-5 K 较大时的 K -最近邻分类

8.2.2 K-近邻实例

首先先来介绍一下实例的背景: 一家银行的工作人员通过电话调查客户是否会愿意



►第七章，第九章读书笔记◀

k 最近邻算法与异常检测属于监督学习分类方法，核心就是“找相似”，看待分类数据点周围 k 个最近的已知数据属于哪类，少数服从多数定类别；做连续值预测时，离得越近的邻居权重越高。k 太小容易被数据噪声带偏，出现过拟合；k 太大又会忽略数据本身的规律，导致欠拟合。二分类一般选奇数避免投票平局，最优 k 值常用交叉验证来调。比如靠化学成分区分红白葡萄酒，准确率能到 98% 以上；也能做异常检测，通过预测误差找出偏离整体的数据，还能反推补充数据特征





图 7-2 使用不同的 k 值进行拟合。黑色区域中的点被预测为白葡萄酒，红色区域中的点则被预测为红葡萄酒

如果 k 值太小，数据点只与最近的“邻居”匹配，并且随机噪声所产生的误差也会被放大，如图 7-2a 所示。如果 k 值太大，数据点会尝试与更远的“邻居”匹配，其中隐含的模式会被忽略，如图 7-2c 所示。

只有当 k 值恰到好处时，数据点才会参考合适数量的“邻居”，这使得误差相互抵消，有利于揭示数据中隐藏的趋势，如图 7-2b 所示。

为实现理想拟合并把误差降到最低，可以使用交叉验证法对参数 k 进行调优（请参考 1.4.3 节）。对于二分类问题，可以把 k 设置成一个奇数，以避免出现平局的情况。

除了用来为数据点分类， k 最近邻算法还可以通过合计周围数据点的值来预测连续值。相比于平等看待周围的所有数据点并简单地取平均值，通过使用加权平均值，能够进一步改善预测结果。离数据点越近的“邻居”，其值越能反映该数据点的真实值，因此赋给它的权重应该更大。



决策树算法核心像做一连串二元选择题，把数据集不断拆分，让每一组数据的共性越来越高，最终形成树状结构，根节点是初始特征，叶节点是预测结果，分类、连续值预测都能用。核心是递归拆分，先选最优特征把数据分成两组，再对每组重复拆分，直到节点内数据类别统一、数量太少或拆分没意义就停止。结果一目了然，能清楚看到每个特征的决策逻辑，不用复杂数学计算；对异常值不敏感，也能直接处理不同类型的数据，预处理步骤少。比如分析泰坦尼克号数据，能清晰得出“女性 / 男孩 + 非三等舱生还概率更高”的规律，直观体现特征对结果的影响。




图 9-2 使用决策树判断一个人能否逃离泰坦尼克号