



第二次作业

信管2302钟京序
202321054056



一、回归方法的基本方法、步骤



一、回归方法的基本方法、步骤

- 回归方法定义

处理变量之间相关关系的一种数学方法

- 解决问题步骤:

1. 收集一组包含因变量和自变量的数据
2. 选定因变量和自变量之间的模型, 利用数据按最小二乘等准则计算模型系数
3. 利用统计分析方法对不同模型进行比较, 找出效果最好的模型
4. 判断得到的模型是否适合这组数据
5. 利用模型对因变量作出预测或解释

- 回归分类

根据回归方法中因变量的个数和回归函数的类型(线性或非线性)可将回归方法分为以下几种:一元线性、一元非线性、多元线性、多元非线性。另外还有两种特殊的回归方式, 一种在回归过程中可以调整变量数的回归方法, 称为逐步回归, 另一种是以指数结构函数

作为回归模型的回归方法, 称为 Logistic 回归。

➤ 二、一元线性回归与多元线性回归 ◀

一元线性回归模型

- 总体回归模型: $y = \beta_0 + \beta_1 x + \varepsilon$

y : 因变量 (被解释变量)

x : 自变量 (解释变量)

β_0 : 截距项, $x=0$ 时 y 的期望值

β_1 : 斜率项, x 每变动一单位 y 的平均变动量

ε : 随机误差项

- 样本回归模型: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

$\hat{y}$: 因变量估计值 (拟合值)

残差 $e = y - \hat{y}$

- 多元线性回归模型 (总体) :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

偏回归系数 β_1 : 控制其他自变量不变时, x_1 变动对 y 的影响

- 矩阵表示法: $Y = X\beta + \varepsilon$

OLS估计: $\hat{\beta} = (X^T X)^{-1} X^T Y$



三、Logistic回归

Logistic回归

- Logistic回归基本数学模型

虽然名称为"回归", 但主要用于分类问题 (二分类)

基础依然是线性模型: $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$

预测值严格落在(0,1)之间

- 与普通线性回归的联系与区别

联系: Logistic回归的基础仍是线性模型

区别: 普通线性回归预测连续值, Logistic回归预测分类概率

Logistic回归通过Sigmoid函数将线性组合映射到(0,1)区间

- 特点

适用于二分类问题

输出结果为概率值, 具有可解释性

决策边界为线性



四、读书笔记



读书笔记

- 拟合 (Fitting)
- 核心逻辑：函数逼近
- 通常对应监督学习中的回归问题
- 既有自变量 X ，也有明确的结果变量 Y
- 目的：找出数学公式 $Y=f(X)$ ，使曲线尽可能穿过现有数据点
- 关键：寻找变量的规律与趋势（描绘轨迹）




图 7-2 使用不同的 k 值进行拟合。黑色区域中的点被预测为白葡萄酒，红色区域中的点则被预测为红葡萄酒

如果 k 值太小，数据点只与最近的“邻居”匹配，并且随机噪声所产生的误差也会被放大，如图 7-2a 所示。如果 k 值太大，数据点会尝试与更远的“邻居”匹配，其中隐含的模式会被忽略，如图 7-2c 所示。

只有当 k 值恰到好处时，数据点才会参考合适数量的“邻居”，这使得误差相互抵消，有利于揭示数据中隐藏的趋势，如图 7-2b 所示。


为实现理想拟合并把误差降到最低，可以使用交叉验证法对参数 k 进行调优（请参考 1.4.3 节）。对于二分类问题，可以把 k 设置成一个奇数，以避免出现平局的情况。

除了用来为数据点分类， k 最近邻算法还可以通过合计周围数据点的值来预测连续值。相比于平等看待周围的所有数据点并简单地取平均值，通过使用加权平均值，能够进一步改善预测结果。离数据点越近的“邻居”，其值越能反映该数据点的真实值，因此赋给它的权重应该更大。

读书笔记

- 聚类 (Clustering)
- 核心逻辑：无监督学习
- 事先不知道数据属于什么类别，也没有目标变量Y作为"标准答案"
- 任务：让算法自行发现数据内部结构，将相似样本归为一类
- 关键：寻找隐藏的群体（物以类聚）

从图 6-1 可以看出，价格较高的房子通常房间数较多。为了预测房价，我们画了一条趋势线（图中的蓝线）。这条趋势线亦称最佳拟合线，大部分数据点都分布在这条线附近。由此预测，一所拥有 8 个房间的房子售价大约是 38.15 万美元。



7.2 物以类聚，人以群分

最近邻算法 根据周围数据点的类型对某个数据点进行归类。也就是说，如果一个数据点周围有 4 个红点和 1 个黑点（如图 7-1 所示），那么根据少数服从多数的原则，这个数据点很可能就是红色的。




图 7-1 根据周围 5 个数据点的颜色以及少数服从多数的原则，中心数据点应该被划为红点

在 **最近邻算法** 中，参数 k 表示周围数据点的个数。在上面的例子中， k 为 5。选择 k 值的过程叫作 **参数调优**，它对预测的准确度起着至关重要的作用。



THANKS FOR WATCHING



信管2302钟京序
202321054056