



第六次作业

信管2302钟京序
202321054056

➤ 数据处理的小细节) 为什么 X 必须是列向量? 变成行向量会怎么样呢? ◀

数据处理的小细节）为什么X必须是列向量？变成行向量会怎么样呢？

在回归模型 $y = b_0 + b_1 \cdot X$ 中， X 作为自变量矩阵，形状要求为 (样本数, 特征数)。

当 X 是列向量（比如 (50, 1)）时，代表50 个样本、1 个特征，和模型运算的矩阵维度匹配（可以和系数 b_1 正确相乘）。

如果变成行向量（比如 (1, 50)），会导致维度不匹配：

矩阵乘法无法执行，程序会直接报错；

逻辑上变成了“1 个样本、50 个特征”，和数据的实际含义矛盾，模型无法正常拟合。

```
In [17]: import pandas as pd
import matplotlib.pyplot as plt
dataset = pd.read_csv(r"C:\Users\zjx25\mycode\studentscores.csv")
dataset.head()
X = dataset.iloc[:,0:1].values
X
X.shape
print(type(X))
Y = dataset.iloc[:,1:2].values
Y
<class 'numpy.ndarray'>


Out[17]: array([[21],
 [47],
 [27],
 [75],
 [30],
 [20],
 [88],
 [60],
 [81],
 [29],
 [85],
 [62],
 [41],
 [42],
 [17],
 [95],
 [30],
 [24],
 [67],
 [69],
 [30],
 [54],
 [35],
 [76],
 [80]], dtype=int64)
```

➤ 如何显示生成的“熟模型”？ $y = b_0 + b_1 * x$, b_0 和 b_1 怎么获得？ ➤

如何显示生成的“熟模型”？ $y = b_0 + b_1 * x$, b_0 和 b_1 怎么获得？

```
In [18]: from sklearn.model_selection import train_test_split
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2, random_state = 0)
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor
regressor = regressor.fit(X, Y)
Y_pred0 = regressor.predict(X)
plt.scatter(X, Y, color = 'red')
plt.scatter(X, Y_pred0, color = 'black')
plt.plot(X, regressor.predict(X), color = 'blue')
```

Out[18]: [<matplotlib.lines.Line2D at 0x2919e22f940>]



```
In [23]: b1 = regressor.coef_ # 系数
b1
```

Out[23]: array([[9.91065648]])

```
In [24]: b0 = regressor.intercept_ # 截距  $y = 2 + 9.9x$ 
b0
```

Out[24]: array([2.01816004])

➤ 如何评价结果的好坏（代码）
R²的结果是什么？ ➤

如何评价结果的好坏（代码） R^2 的结果是什么？

```
In [25]: R2_train = regressor.score(X_train, Y_train)
         R2_train
```

```
Out[25]: 0.9515510725211553
```

```
In [26]: R2_test = regressor.score(X_test, Y_test)
         R2_test
```

```
Out[26]: 0.9454906892105356
```

取值范围：0 ~ 1（部分特殊情况会出现负数）

含义：越接近 1，说明模型对数据的拟合效果越好；越接近 0，说明模型几乎无法解释数据的变化。

►调整训练/测试的比例，对结果◀
(R^2) 有什么影响？

调整训练/测试的比例，对结果 (R^2) 有什么影响？

```
In [46]: X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.5, random_state = 1)
```

```
In [47]: R2_train = regressor.score(X_train, Y_train)
R2_train
```

```
Out[47]: 0.9676216415968816
```

```
In [42]: R2_test = regressor.score(X_test, Y_test)
R2_test
```

```
Out[42]: 0.9357744340622637
```

```
In [48]: X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.2, random_state = 1)
```

```
In [49]: R2_train = regressor.score(X_train, Y_train)
R2_train
```

```
Out[49]: 0.9604565929994506
```

```
In [50]: R2_test = regressor.score(X_test, Y_test)
R2_test
```

```
Out[50]: 0.8965050057871
```

```
In [52]: X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.05, random_state = 1)
```

```
In [53]: R2_train = regressor.score(X_train, Y_train)
R2_train
```

```
Out[53]: 0.9530617388569461
```

```
In [54]: R2_test = regressor.score(X_test, Y_test)
R2_test
```

```
Out[54]: 0.7772885126865112
```

训练集过小时模型学习的数据太少，
容易欠拟合，训练集和测试集的 R^2 都会
偏低



THANKS FOR WATCHING



信管2302钟京序
202321054056